

SEMINAR · HỌC MÁY VỚI DỮ LIỆU ĐỒ THỊ

HFR-MKGC: Suy luận hợp nhất phân cấp với MLLM cho hoàn thiện đồ thị tri thức đa phương thức

D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, H. Li — AAAI 2026 [1]

GIẢNG VIÊN HƯỚNG DẪN

TS. Lê Ngọc Thành


ThS. Huỳnh Lâm Hải Đăng

NHÓM TRÌNH BÀY

Nguyễn Đình Lộc · 25C11050

Ngô Trương Minh Đạt · 25C15003

Bài toán: nổi cạnh còn thiếu trong đồ thị tri thức



KGC: che một thành phần của bộ ba rồi đoán lại:

(h, r, ?)	che tail, xếp hạng mọi thực thể
(?, r, t)	che head, xếp hạng mọi thực thể
(h, ?, t)	che quan hệ, xếp hạng mọi quan hệ

Bài này làm hai dạng đầu, đánh giá cả hai chiều. Ví dụ bên trái là (h, r, ?).

MMKGC: mỗi thực thể có thêm ảnh và văn bản, ngoài cấu trúc.

Chỉ với cấu trúc (hai cạnh đã biết) thì khó đoán được voice type. Có thêm văn bản ("singer") và ảnh, mô hình có thêm căn cứ để chọn đúng ứng viên.

Ví dụ minh hoạ theo case study [1, Fig. 4]; ảnh và mô tả từ [1, Fig. 4]. Sơ đồ do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>


Hai điểm yếu của MMKGC hiện có

1. Trộn mô thức không phụ thuộc quan hệ

Trọng số cố định cho mọi quan hệ. Ảnh không liên quan tới *voice type* nhưng vẫn có trọng số như các mô thức khác → nhiễu.

2. KGC dựa trên LLM thiếu thích nghi

Chỉ dùng text + cấu trúc, trộn tĩnh, chưa dùng ảnh, không thích nghi theo từng bộ ba.



Nguồn: [1], Fig. 1

HFR-MKGC = RotatE + ba mô-đun

RHF

Relation-guided Hierarchical Fusion

Tầng 1: trộn *bên trong* ảnh (CLIP + caption).

Tầng 2: trộn S/I/T với trọng số **tính từ quan hệ r**.

MER

MLLM-Enhanced Reasoning

LLaVA (LoRA) đoán thẳng tên đáp án; đưa vào hàm điểm qua một **cổng** học được.

MNO

Multi-modal Negative Optimization


Mẫu sai khó: LLaVA viết lại text, xoay + nhiễu vector ảnh. Train **đối kháng**.

Nền: hàm điểm **RotatE** [2], encoder **CLIP**^a và **BERT**^b đóng băng, **LLaVA-1.5-7B** [3].

Không dùng GNN. Mỗi node là một hàng trong bảng embedding; cấu trúc đồ thị đi vào mô hình qua hàm loss, không qua truyền tin.


^a A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021. ^b J. Devlin et al., "BERT," NAACL 2019.

Kiến trúc tổng thể



Nguồn: [1], Fig. 2

Một node = ba vector, một quan hệ = một vector



Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Lưu: 3 vector/node. Tính: trộn lại với tỉ lệ khác nhau tùy quan hệ. Số tham số không tăng theo số quan hệ.

RHF · Tầng 1: trộn bên trong mô thức ảnh

$$e_I = \sigma(\langle e_{lv}, e_{lc} \rangle) \cdot e_{lc} + (1 - \sigma(\langle e_{lv}, e_{lc} \rangle)) \cdot e_{lv} \quad (1)$$

e_{lv} ảnh → CLIP → chiếu: thị giác thô

e_{lc} ảnh → LLaVA viết caption → BERT → chiếu: ngữ nghĩa

$\langle \cdot, \cdot \rangle$ tích vô hướng: độ tương đồng giữa hai vector

σ sigmoid → tỉ lệ trong (0,1)


e_I một vector ảnh duy nhất đi tiếp

Độ tương đồng cao → tăng trọng số caption (dạng ngôn ngữ, gần KG).

Độ tương đồng thấp → caption có thể sai, giữ trọng số CLIP.

Cổng không có tham số. Tham số học được nằm ở hai lớp chiếu P_I , P_T , đưa CLIP (512) và BERT (768) về cùng chiều.

Caption ví dụ: "A Golden Retriever carrying a stick in its mouth" [1, Fig. 1].



đóng băng: CLIP, LLaVA, BERT · học: P_I , P_T · cổng: không tham số

Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

RHF · Tầng 2: trộn ba mô thức theo quan hệ

$$\alpha_m = \langle e_m, r \rangle + (1/3) \sum_j \langle e_m, e_j \rangle \quad (2)$$


$$w_m = \text{softmax}(\alpha_m - \bar{\alpha}) \quad H_{\text{joint}} = \sum_m w_m \cdot e_m \quad (3), (4)$$

$\langle e_m, r \rangle$ mô thức m hợp với quan hệ r bao nhiêu → **đổi theo r**

tb $\langle e_m, e_j \rangle$ m nhất quán với hai mô thức kia không → lọc mô thức thiếu / bịa

w_m ba tỉ lệ, tổng = 1, đổi theo **cả node lẫn quan hệ**

H_{joint} vector node cho câu hỏi này




Tỉ lệ minh hoạ theo [1, Fig. 4]. Hình do AI tạo (Claude), nguồn:
<https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Cùng node, quan hệ khác → $\langle e_m, r \rangle$ khác → trọng số khác. Không có ma trận học riêng: tương đương attention với query = r, key = e_m .

MER: MLLM đoán đáp án, cổng quyết định tin bao nhiêu

- 1 **Prompt** = phần cố định (nhiệm vụ, định dạng) + text của h, lát giềng của h (bằng tên), ảnh h, quan hệ r → **LLaVA** + **LoRA**^a → một tên: "*Mezzo-soprano*" (5)
- 2 Tên → BERT → chiều → **T_MLLM** (2d số). Chỉ làm **một lần** mỗi câu hỏi.
- 3 Cổng: $g = \sigma(W_2 \cdot \tanh(W_1 \cdot T_{\text{MLLM}} + b_1) + b_2) \in (0,1)^{\{2d\}}$ — MLP $2d \rightarrow d \rightarrow 2d$, **có tham số học** (7)
- 4 Với **mỗi** ứng viên t: $\tilde{T}(t) = (1 - g) \circ T_{\text{joint}}(t) + g \circ T_{\text{MLLM}}$, tách phần thực / ảo (8–9)




g không phụ thuộc ứng viên và câu hỏi. Nếu LLaVA sai, mọi ứng viên bị kéo về cùng một điểm sai. Cổng chỉ đánh giá độ tin cậy của đáp án, không đánh giá mức phù hợp với câu hỏi.

Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Chấm điểm bằng RotatE: quan hệ là phép xoay

$$r_C = \cos(r/(\gamma/\pi)) + i \cdot \sin(r/(\gamma/\pi)) \quad \text{score} = -\| H_joint \circ r_C - \tilde{T} \| \quad (6), (10)$$



r_C r đổi thành d góc; mô-đun 1 $\rightarrow$ chỉ xoay, không co giãn

$H \circ r_C$ xoay head trên từng mặt phẳng $\rightarrow$ điểm neo, tính 1 lần

$\tilde{T}$ ứng viên sau cổng; đo 15 000 lần

$\|\cdot\|$ khoảng cách gộp mọi mặt phẳng; gần $\rightarrow$ điểm cao

γ thang đổi r sang góc

Một mặt phẳng phức trong d mặt phẳng. Hình do AI tạo (Claude), nguồn:
<https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Vì sao RotatE [2]: một phép xoay biểu diễn được đối xứng ($\theta = \pi$), nghịch đảo ($-\theta$), hợp thành ($\theta_1 + \theta_2$). Cài đặt bằng 2d số thực, không cần kiểu số phức.

MNO: mẫu sai khó và huấn luyện đối kháng

Text giả

LLaVA viết lại mô tả: "American singer..." → "US-based vocalist..." → BERT → chiếu.

Ảnh giả (11)

$$\hat{e}_v = ((1-\lambda)I + \lambda R) \cdot x_v + \varepsilon$$

R


ma trận xoay (QR của ma trận ngẫu nhiên hạng thấp)

λ

0 → 1 tăng theo epoch: dễ trước, khó sau

ε

nhiễu Gauss



$L_D = L_{kgc} + \text{gradient penalty (14), tối ưu xen kẽ}$

Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

- L_kgc


loss self-adversarial của RotatE [2]: mẫu sai điểm cao bị phạt nặng hơn (12)
- c

ngưỡng: mẫu giả dưới c thì generator bị phạt
- GP

ép $\|\nabla D\| \approx 1$ để GAN ổn định^a

Với λ nhỏ, mẫu giả gần như trùng node gốc. Bài không kiểm chứng các mẫu này có thực sự sai.

Luồng dữ liệu cho một truy vấn (h, r, ?)



Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>. Lúc train: thêm mẫu sai (MNO), tính loss, cập nhật E, R, P_m, cổng, LoRA.

Dữ liệu và độ đo

Dataset	Nguồn	#Entity	#Rel	#Train	#Valid	#Test	có ảnh	có text
MKG-W	Wikidata ^a	15 000	169	34 196	4 276	4 274	96%	94%
MKG-Y	YAGO ^a	15 000	28	21 310	2 665	2 663	95%	82%
DB15K	DBpedia ^b	12 842	279	79 222	9 902	9 904	99.8%	71%

Tỉ lệ có ảnh / text tự tính từ [1, Table 2]. DB15K thiếu text nhiều nhất; MKG-Y chỉ 28 quan hệ nên cấu trúc đã mạnh.


MRR
Trung bình 1/hạng của đáp án đúng. Hạng 1 → 1.0, hạng 10 → 0.1.

Hits@K
Tỉ lệ đáp án đúng nằm trong top K. Hits@1 khó nhất, Hits@10 dễ nhất.

Mỗi bộ ba test hỏi cả hai chiều (đoán tail, đoán head), lọc các đáp án đúng khác (filtered). 14 baseline được tác giả chạy lại với cùng CLIP/BERT.

^a D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022. ^b Y. Liu et al., "MMKG: multi-modal knowledge graphs," ESWC 2019.

Kết quả chính (MRR, %)



Hơn baseline tốt nhất (NativeE): **+1.83** MKG-W, **+0.66** MKG-Y, **+1.61** DB15K.

Đứng đầu **11/12** ô (MRR, Hits@1/3/10 × 3 tập).

Ngoại lệ: Hits@1 trên DB15K 23.04 thua RSME 24.45, APKGC 24.39, MyGO 24.19.

LLaVA thuần (prompt, không hàm điểm): Hits@10 chỉ 26% trên MKG-W, 3.6% trên MKG-Y.

Vẽ lại từ [1, Table 1]. Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

[1] Table 1. ^a Y. Zhang et al., "NativeE: Multi-modal KGC in the wild," SIGIR 2024.

Ablation trên MKG-W



MRR. Vẽ lại từ [1, Table 3]. Hình do AI tạo (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

RHF đóng góp lớn nhất trong 4 mô-đun: Hits@1 rớt 31.4 → 20.8 nhưng Hits@10 gần giữ nguyên → trộn theo quan hệ chủ yếu giúp **xếp đúng hạng 1**.

Cấu trúc vẫn là mô thức quan trọng nhất (−13). Text (−9) hơn ảnh (−7.5).

Caption do LLaVA sinh có ích thật (−6.8 khi bỏ).

Ablation chỉ làm trên MKG-W, không kiểm tra hai tập kia.



Có RHF: trọng số text tăng, ảnh giảm → **hạng 1.**

Nhận xét và hạn chế

Chi phí

LLaVA-7B chạy cho mỗi ảnh (caption), mỗi truy vấn (đoán), mỗi text (viết lại). Không báo cáo thời gian.

Tái lập

Không công khai code. Nhiều baseline do tác giả tự chạy lại.

Cải thiện không đều

MKG-Y chỉ +0.66. Thua Hits@1 trên DB15K. Ablation một tập.

Cổng G không dùng ngữ cảnh

g chỉ phụ thuộc đáp án LLaVA, không phụ thuộc câu hỏi. Không có phân tích về g hay tỉ lệ LLaVA đoán đúng.

Tính đúng đắn của mẫu giả

Paraphrase cùng nghĩa và ảnh xoay nhẹ vẫn biểu diễn node gốc. Ngược hướng contrastive của MDBGF.

Căn chỉnh gián tiếp

Tích vô hướng giữa CLIP và BERT chỉ có nghĩa nhờ lớp chiếu học qua loss KGC; không có loss căn chỉnh riêng.

Thiếu chi tiết: prompt, epoch LoRA, cách chọn láng giềng, γ , c , τ , μ_1 , có chuẩn hoá vector trước tích vô hướng hay không.

Kết luận

- **Ý chính:** trọng số trộn mô thức phụ thuộc quan hệ đang xét. Cùng node, khác quan hệ, khác vector biểu diễn.
- **Phương pháp:** giữ RotatE làm hàm điểm; đầu vào là vector đã trộn ba mô thức theo r , bổ sung dự đoán của MLLM qua cổng; huấn luyện với mẫu sai khó.
- **Bằng chứng:** +1.8 MRR trên MKG-W; RHF là mô-đun đóng góp nhiều nhất; cấu trúc vẫn là mô thức quan trọng nhất.
- **Hạn chế:** chi phí MLLM, cổng không dùng ngữ cảnh câu hỏi, mẫu giả chưa được kiểm chứng, không có code.

HFR-MKGC = RotatE + trộn mô thức có dẫn hướng bởi quan hệ + dự đoán MLLM qua cổng có kiểm soát + huấn luyện đối kháng với mẫu sai đa mô thức.

Tài liệu tham khảo

- [1] D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, and H. Li, "HFR-MKGC: Hierarchical Fusion Reasoning with MLLMs for Multi-modal Knowledge Graph Completion," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 18, 2026, pp. 15815–15823.
- [2] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge graph embedding by relational rotation in complex space," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019.
- [3] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 36, 2023, pp. 34892–34916.

Nguồn dùng một lần (đã ghi footnote tại slide)

A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021 · J. Devlin et al., "BERT: Pre-training of deep bidirectional transformers," NAACL 2019 · E. J. Hu et al., "LoRA," ICLR 2022 · I. Gulrajani et al., "Improved training of Wasserstein GANs," NeurIPS 2017 · D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022 · Y. Liu et al., "MMKG," ESWC 2019 · Y. Zhang et al., "Native," SIGIR 2024.

Nguồn hình

Fig. 1, 2, 4: cắt từ PDF của [1]. Các hình còn lại do AI tạo (Claude) theo hướng dẫn của nhóm, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>