

SEMINAR · HỌC MÁY VỚI DỮ LIỆU ĐỒ THỊ


HFR-MKGC: Hierarchical Fusion Reasoning with MLLMs for Multi-modal Knowledge Graph Completion

Suy luận hợp nhất phân cấp với MLLM cho hoàn thiện đồ thị tri thức đa phương thức

D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, H. Li — AAAI 2026 [1]

Trình bày: Nguyễn Đình Lộc (25C11050) · Ngô Trương Minh Đạt (25C15003)

Bài toán: nổi cạnh còn thiếu trong đồ thị tri thức



KGC: cho $(h, r, ?)$, xếp hạng **mọi** thực thể, đáp án đúng phải đứng đầu.

MMKGC: mỗi thực thể có thêm **ảnh** và **văn bản**, ngoài **cấu trúc**.

Không phải bài toán thêm node mới: mọi node đã có trong bảng, chỉ thiếu cạnh (transductive).

Ví dụ input → output

Input: (Gwen Stefani, voice type, ?)

- S** lảng giềng: No Doubt, Anaheim, ... (minh hoạ)
- T** "Gwen Renée Stefani (born 1969) is an American singer, songwriter, actress..."
- I** ảnh chân dung
- r** voice type

Output: bảng xếp hạng 15 000 thực thể

Hạng	Ứng viên	score
1	Mezzo-soprano	-1.07
2	Double bass	-1.35
3	Soprano	-1.52
...	...	...

Điểm minh hoạ. Thứ hạng lấy từ case study của bài [1, Fig. 4].

Ảnh không chứa thông tin về giọng hát; văn bản chứa từ khoá "singer". Với quan hệ voice type, mô hình cần **ưu tiên văn bản** hơn ảnh.


Hai điểm yếu của MMKGC hiện có

1. Trộn mô thức không phụ thuộc quan hệ

Trọng số cố định cho mọi quan hệ. Ảnh không liên quan tới *voice type* nhưng vẫn có trọng số như các mô thức khác → nhiễu.

2. KGC dựa trên LLM thiếu thích nghi

Chỉ dùng text + cấu trúc, trộn tĩnh, chưa dùng ảnh, không thích nghi theo từng bộ ba.



Nguồn: [1], Fig. 1

HFR-MKGC = RotatE + ba mô-đun

RHF

Relation-guided Hierarchical Fusion

Tầng 1: trộn *bên trong* ảnh (CLIP + caption).

Tầng 2: trộn S/I/T với trọng số **tính từ quan hệ r**.

MER

MLLM-Enhanced Reasoning

LLaVA (LoRA) đoán thẳng tên đáp án; đưa vào hàm điểm qua một **cổng** học được.

MNO

Multi-modal Negative Optimization


Mẫu sai khó: LLaVA viết lại text, xoay + nhiễu vector ảnh. Train **đối kháng**.

Nền: hàm điểm **RotatE** [2], encoder **CLIP**^a và **BERT**^b đóng băng, **LLaVA-1.5-7B** [3].

Không dùng GNN. Mỗi node là một hàng trong bảng embedding; cấu trúc đồ thị đi vào mô hình qua hàm loss, không qua truyền tin.


^a A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021. ^b J. Devlin et al., "BERT," NAACL 2019.

Kiến trúc tổng thể



Nguồn: [1], Fig. 2

Một node = ba vector, một quan hệ = một vector



Lưu: 3 vector/node. Tính: trộn lại với tỉ lệ khác nhau tùy quan hệ. Số tham số không tăng theo số quan hệ.

RHF · Tầng 1: trộn bên trong mô thức ảnh

$$e_I = \sigma(\langle e_{Iv}, e_{Ic} \rangle) \cdot e_{Ic} + (1 - \sigma(\langle e_{Iv}, e_{Ic} \rangle)) \cdot e_{Iv} \quad (1)$$

e_{Iv} ảnh → CLIP → chiều: thị giác thô

e_{Ic} ảnh → LLaVA viết caption → BERT → chiều: ngữ nghĩa

$\langle \cdot, \cdot \rangle$ tích vô hướng: độ tương đồng giữa hai vector

σ sigmoid → tỉ lệ trong (0,1)


e_I một vector ảnh duy nhất đi tiếp

Độ tương đồng cao → tăng trọng số caption (dạng ngôn ngữ, gần KG).

Độ tương đồng thấp → caption có thể sai, giữ trọng số CLIP.

Cổng không có tham số. Tham số học được nằm ở hai lớp chiều P_I , P_T , đưa đầu ra CLIP và BERT về cùng d chiều.

Caption ví dụ: "A Golden Retriever carrying a stick in its mouth" [1, Fig. 1].



đóng băng: CLIP, LLaVA, BERT · học: P_I , P_T · cổng: không tham số

RHF · Tầng 2: trộn ba mô thức theo quan hệ

$$\alpha_m = \langle e_m, r \rangle + (1/3) \sum_j \langle e_m, e_j \rangle \quad (2)$$

$$w_m = \text{softmax}(\alpha_m - \bar{\alpha}) \quad \mathbf{H}_{\text{joint}} = \sum_m w_m \cdot e_m \quad (3), (4)$$


$\langle e_m, r \rangle$ mô thức m hợp với quan hệ r bao nhiêu → **đổi theo r**

$\text{tb}\langle e_m, e_j \rangle$ m nhất quán với hai mô thức kia không → lọc mô thức thiếu / bịa

w_m ba tỉ lệ, tổng = 1, đổi theo **cả node lẫn quan hệ**

$\mathbf{H}_{\text{joint}}$ vector node cho câu hỏi này

Gwen Stefani, r = voice type




Tỉ lệ minh hoạ do nhóm đặt theo xu hướng của [1, Fig. 4].

Cùng node, quan hệ khác → $\langle e_m, r \rangle$ khác → trọng số khác. Không có ma trận học riêng: tương đương attention với query = r, key = e_m .

MER: MLLM đoán đáp án, công quyết định tin bao nhiêu


- 1 **Prompt** = nhiệm vụ cố định + text, lát giềng, ảnh của h và quan hệ r → **LLaVA + LoRA^a** → một tên: "*Mezzo-soprano*" (5)
- 2 Tên → BERT → chiều → $\mathbf{T}_{\text{MLLM}}$. Tính **một lần** mỗi câu hỏi.
- 3 Công $\mathbf{g} = \sigma(W_2 \cdot \tanh(W_1 \cdot \mathbf{T}_{\text{MLLM}} + \mathbf{b}_1) + \mathbf{b}_2) \in (0,1)^{2d}$: MLP hai lớp, **có tham số học** (7)
- 4 Với **mỗi** ứng viên t: $\tilde{\mathbf{T}}(t) = (1 - \mathbf{g}) \circ \mathbf{T}_{\text{joint}}(t) + \mathbf{g} \circ \mathbf{T}_{\text{MLLM}}$, tách phần thực / ảo (8–9)



g chỉ nhìn đáp án, không nhìn câu hỏi hay ứng viên.
LLaVA sai thì mọi ứng viên bị kéo về cùng một điểm sai.

Chấm điểm bằng RotatE: quan hệ là phép xoay

$$\mathbf{r}_C = \cos(\mathbf{r}/(\gamma/\pi)) + i \cdot \sin(\mathbf{r}/(\gamma/\pi)) \quad \text{score} = -\| \mathbf{H}_{\text{joint}} \circ \mathbf{r}_C - \tilde{\mathbf{T}} \| \quad (6), (10)$$



Một mặt phẳng phức trong d mặt phẳng.

- $\mathbf{r}_C$ r đổi thành d góc; mô-đun 1 → chỉ xoay, không co giãn
- $\mathbf{H} \circ \mathbf{r}_C$ xoay head trên từng mặt phẳng → điểm neo, tính 1 lần
- $\tilde{\mathbf{T}}$ ứng viên sau cổng; đo 15 000 lần
- $\|\cdot\|$ khoảng cách gộp mọi mặt phẳng; gần → điểm cao
- γ thang đổi r sang góc

Vì sao RotatE [2]: một phép xoay biểu diễn được đối xứng ($\theta = \pi$), nghịch đảo ($-\theta$), hợp thành ($\theta_1 + \theta_2$). Cài đặt bằng 2d số thực, không cần kiểu số phức.

MNO: mẫu sai khó và huấn luyện đối kháng

Text giả

LLaVA viết lại mô tả: "American singer..." → "US-based vocalist..." → BERT → chiếu.


Ảnh giả (11)

$$\hat{\mathbf{e}}_v = ((1 - \lambda) \mathbf{I} + \lambda \mathbf{R}) \cdot \mathbf{x}_v + \epsilon$$

$\mathbf{R}$ ma trận xoay (QR của ma trận ngẫu nhiên hạng thấp)

λ 0 → 1 tăng theo epoch: dễ trước, khó sau

ϵ nhiễu Gauss



$L_D = L_{kgc} + \text{gradient penalty (14)}$, tối ưu xen kẽ


L_{kgc} loss self-adversarial của RotatE [2]: mẫu sai điểm cao bị phạt nặng hơn (12)

c ngưỡng: mẫu giả dưới c thì generator bị phạt

GP ép $\|\nabla D\| \approx 1$ để GAN ổn định^a

Với λ nhỏ, mẫu giả gần như trùng node gốc. Bài không kiểm chứng các mẫu này có thực sự sai.

Luồng dữ liệu cho một truy vấn (h, r, ?)



Lúc train: thêm mẫu sai (MNO), tính loss, cập nhật E, R, P_m , công, LoRA.

Dữ liệu và độ đo

Dataset	Nguồn	#Entity	#Rel	#Train	#Valid	#Test	có ảnh	có text
MKG-W	Wikidata ^a	15 000	169	34 196	4 276	4 274	96%	94%
MKG-Y	YAGO ^a	15 000	28	21 310	2 665	2 663	95%	82%
DB15K	DBpedia ^b	12 842	279	79 222	9 902	9 904	99.8%	71%

Tỉ lệ có ảnh / text tự tính từ [1, Table 2]. DB15K thiếu text nhiều nhất; MKG-Y chỉ 28 quan hệ nên cấu trúc đã mạnh.

MRR

Trung bình 1/hạng của đáp án đúng. Hạng 1 → 1.0, hạng 10 → 0.1.


Hits@K

Tỉ lệ đáp án đúng nằm trong top K. Hits@1 khó nhất, Hits@10 dễ nhất.

Đánh giá theo thông lệ KGC: hỏi cả hai chiều, filtered (bài không nêu rõ, nhóm giả định). 14 baseline được tác giả chạy lại với cùng CLIP/BERT.

^a D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022. ^b Y. Liu et al., "MMKG: multi-modal knowledge graphs," ESWC 2019.

Kết quả chính (MRR, %)



Vẽ lại từ [1, Table 1].

Hơn baseline tốt nhất (NativeE): **+1.83** MKG-W, **+0.66** MKG-Y, **+1.61** DB15K.

Đứng đầu **11/12** ô (MRR, Hits@1/3/10 × 3 tập).

Ngoại lệ: Hits@1 trên DB15K 23.04 thua RSME 24.45, APKGC 24.39, MyGO 24.19.

LLaVA thuần (prompt, không hàm điểm): Hits@10 chỉ 26% trên MKG-W, 3.6% trên MKG-Y.

Ablation trên MKG-W



MRR. Vẽ lại từ [1, Table 3].


RHF đóng góp lớn nhất trong 4 mô-đun: Hits@1 rớt 31.4 → 20.8 nhưng Hits@10 gần giữ nguyên → trộn theo quan hệ chủ yếu giúp **xếp đúng hạng 1**.

Cấu trúc vẫn là mô thức quan trọng nhất (−13). Text (−9) hơn ảnh (−7.5).

Caption do LLaVA sinh có ích thật (−6.8 khi bỏ).

Ablation chỉ làm trên MKG-W, không kiểm tra hai tập kia.

Case study: trọng số đổi theo quan hệ



Nguồn: [1], Fig. 4

Không có RHF (trọng số ngẫu nhiên): ảnh có trọng số cao nhất dù chỉ chứa ngoại hình → Mezzo-soprano **hạng 2**.

Có RHF: trọng số text tăng, ảnh giảm → **hạng 1**.

Cùng ví dụ input–output ở slide 3: cùng ba vector, trọng số khác, kết quả khác.

Nhận xét và hạn chế

Chi phí

LLaVA-7B chạy cho mỗi ảnh (caption), mỗi truy vấn (đoán), mỗi text (viết lại). Không báo cáo thời gian.

Tái lập

Không công khai code. Nhiều baseline do tác giả tự chạy lại.

Cải thiện không đều

MKG-Y chỉ +0.66. Thua Hits@1 trên DB15K. Ablation một tập.

Cổng G không dùng ngữ cảnh

g chỉ phụ thuộc đáp án LLaVA, không phụ thuộc câu hỏi. Không có phân tích về g hay tỉ lệ LLaVA đoán đúng.

Tính đúng đắn của mẫu giả

Paraphrase cùng nghĩa và ảnh xoay nhẹ vẫn biểu diễn node gốc; bài không kiểm chứng mẫu giả có thực sự sai.

Căn chỉnh gián tiếp

Tích vô hướng giữa CLIP và BERT chỉ có nghĩa nhờ lớp chiếu học qua loss KGC; không có loss căn chỉnh riêng.

Thiếu chi tiết để tái lập: prompt, epoch LoRA, cách chọn láng giềng, các siêu tham số γ , c , τ , μ_1 .

Kết luận

- **Ý chính:** trọng số trộn mô thức phụ thuộc quan hệ đang hỏi.
- **Phương pháp:** RotatE làm hàm điểm; vector đã trộn theo r ; dự đoán MLLM qua cổng; mẫu sai khó.
- **Bằng chứng:** +1.8 MRR trên MKG-W; RHF đóng góp nhiều nhất; cấu trúc vẫn quan trọng nhất.
- **Hạn chế:** chi phí MLLM; cổng không dùng ngưỡng cảnh; mẫu giả chưa kiểm chứng; không có code.

HFR-MKGC = RotatE + trộn mô thức có dẫn hướng bởi quan hệ + dự đoán MLLM qua cổng có kiểm soát + huấn luyện đối kháng với mẫu sai đa mô thức.

Tài liệu tham khảo

- [1] D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, and H. Li, "HFR-MKGC: Hierarchical Fusion Reasoning with MLLMs for Multi-modal Knowledge Graph Completion," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 18, 2026, pp. 15815–15823.
- [2] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge graph embedding by relational rotation in complex space," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019.
- [3] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 36, 2023, pp. 34892–34916.

Nguồn dùng một lần (đã ghi footnote tại slide)

A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021 · J. Devlin et al., "BERT: Pre-training of deep bidirectional transformers," NAACL 2019 · E. J. Hu et al., "LoRA," ICLR 2022 · I. Gulrajani et al., "Improved training of Wasserstein GANs," NeurIPS 2017 · D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022 · Y. Liu et al., "MMKG," ESWC 2019 · Y. Zhang et al., "Native," SIGIR 2024.

Nguồn hình

Fig. 1, 2, 3, 4: cắt từ PDF của [1]. Các sơ đồ không ghi nguồn tại slide (slide 2, 7–13, 15, 16) do nhóm vẽ với sự hỗ trợ của AI (Claude). Bản vẽ: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>. Cuộc trò chuyện hướng dẫn tạo và chỉnh sửa: https://claude.ai/code/session_01A6LxsaCfbwEKQ5usCHaXPW


Kết quả đầy đủ trên ba benchmark (%)

Model	W-MRR	W-H@10	W-H@1	Y-MRR	Y-H@10	Y-H@1	DB-MRR	DB-H@10	DB-H@1
RotatE [2]	32.92	44.23	26.68	36.67	41.11	33.92	32.07	51.40	21.23
RSME	33.41	44.31	27.59	38.03	44.02	34.28	33.72	50.39	24.45
MyGO	33.40	44.36	27.52	30.29	42.17	23.75	32.25	48.23	24.19
AdaMF-MAT	32.09	45.78	24.48	37.78	46.11	32.65	32.08	52.42	19.81
APKGC	32.67	46.20	25.24	31.48	40.68	26.17	32.91	48.91	24.39
NativE	36.79	50.28	29.36	38.34	46.24	33.49	33.59	53.77	22.11
LLaMA-2-7B	–	10.20	5.62	–	2.29	1.35	–	14.14	7.15
LLaVA-1.5-7B [3]	–	26.42	15.02	–	3.58	1.64	–	15.89	8.32
HFR-MKGC	38.62	51.66	31.37	39.00	47.31	34.41	35.20	56.41	23.04

W = MKG-W, Y = MKG-Y, DB = DB15K. Rút gọn từ [1, Table 1]: bỏ Hits@3 và các baseline yếu hơn (TransE, DistMult, ComplEx, IKRL, SNAG, DHNS). LLM thuần chỉ sinh 10 ứng viên nên không có MRR.

[1] D. Wang et al., AAAI 2026, Table 1.

Độ nhạy siêu tham số trên MKG-W



Nguồn: [1], Fig. 3

Chiều **512** chỉ đạt 38.62 MRR khi có **128** mẫu sai; với 32 hoặc 64 chỉ khoảng 33.

Chiều **256** tốt nhất với 64 mẫu sai (36.08). Chiều **128** gần như không phụ thuộc số mẫu sai.

MRR và Hits@1 nhạy với siêu tham số; Hits@10 ổn định.

RotatE thuần tăng đều theo chiều (10 → 25 → 33) và không nhạy với số mẫu sai.