


SEMINAR · HỌC MÁY VỚI DỮ LIỆU ĐỒ THỊ

HFR-MKGC: Suy luận hợp nhất phân cấp với MLLM cho hoàn thiện đồ thị tri thức đa phương thức

D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, H. Li — AAAI 2026 [1]

Trình bày: Nguyễn Đình Lộc (25C11050) · Ngô Trương Minh Đạt (25C15003)

Bài toán: nổi cạnh còn thiếu trong đồ thị tri thức



Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

KGC: cho (h, r, ?), xếp hạng **mọi** thực thể, đáp án đúng phải đứng đầu.

MMKGC: mỗi thực thể có thêm **ảnh** và **văn bản**, ngoài **cấu trúc**.

Không phải bài toán thêm node mới. Mọi node đã có trong bảng, chỉ thiếu cạnh.

Ví dụ input → output

Input: (Gwen Stefani, voice type, ?)

S lảng giềng: No Doubt, Anaheim, Gavin Rossdale...

T "Gwen Renée Stefani (born 1969) is an American singer, songwriter, actress..."

I ảnh chân dung

r voice type

Output: bảng xếp hạng 15 000 thực thể

Hạng	Ứng viên	score
1	Mezzo-soprano	-1.07
2	Double bass	-1.35
3	Soprano	-1.52
...	...	...

Điểm minh hoạ. Thứ hạng lấy từ case study của bài [1, Fig. 4].

Ảnh không nói gì về giọng hát, văn bản thì có chữ "singer". Mô hình tốt phải biết **nghe văn bản nhiều hơn ảnh** khi câu hỏi là voice type.


Hai điểm yếu của MMKGC hiện có

1. Trộn mô thức "mù" quan hệ

Trọng số cố định cho mọi quan hệ. Ảnh vô dụng với *voice type* nhưng vẫn được nghe như nhau → nhiễu.

2. LLM cho KGC còn cứng

Chỉ dùng text + cấu trúc, trộn tĩnh, chưa dùng ảnh, không thích nghi theo từng bộ ba.



Nguồn: [1], Fig. 1

HFR-MKGC = RotatE + ba mô-đun

RHF

Relation-guided Hierarchical Fusion

Tầng 1: trộn *bên trong* ảnh (CLIP + caption).

Tầng 2: trộn S/I/T với trọng số **tính từ quan hệ r**.

MER

MLLM-Enhanced Reasoning

LLaVA (LoRA) đoán thẳng tên đáp án; đưa vào hàm điểm qua một **cổng** học được.

MNO

Multi-modal Negative Optimization


Mẫu sai khó: LLaVA viết lại text, xoay + nhiễu vector ảnh. Train **đối kháng**.

Nền: hàm điểm **RotatE** [2], encoder **CLIP**^a và **BERT**^b đóng băng, **LLaVA-1.5-7B** [3].

Không có GNN. Mỗi node là một hàng tra bảng; cấu trúc đi vào mô hình qua hàm loss, không qua truyền tin.


^a A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021. ^b J. Devlin et al., "BERT," NAACL 2019.

Kiến trúc tổng thể



Nguồn: [1], Fig. 2

Một node = ba vector, một quan hệ = một vector



Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Lưu: 3 vector/node. Tính: trộn lại với tỉ lệ khác nhau tùy quan hệ. Số tham số không tăng theo số quan hệ.

RHF · Tầng 1: trộn bên trong mô thức ảnh

$$e_I = \sigma(\langle e_{lv}, e_{lc} \rangle) \cdot e_{lc} + (1 - \sigma(\langle e_{lv}, e_{lc} \rangle)) \cdot e_{lv} \quad (1)$$

e_{lv} ảnh → CLIP → chiếu: thị giác thô

e_{lc} ảnh → LLaVA viết caption → BERT → chiếu: ngữ nghĩa

$\langle \cdot, \cdot \rangle$ tích vô hướng: hai vector "đồng ý" bao nhiêu

σ sigmoid → tỉ lệ trong (0,1)


e_I một vector ảnh duy nhất đi tiếp

Đồng ý nhiều → tin caption (đã ở dạng ngôn ngữ, gần KG).

Đồng ý ít → LLaVA có thể bịa, giữ CLIP.

Không có tham số học ở cổng. Cái học được là hai lớp chiếu P_I , P_T , đưa CLIP (512) và BERT (768) về cùng d chiều để tích vô hướng có nghĩa.

Caption ví dụ: "A Golden Retriever carrying a stick in its mouth" [1, Fig. 1].



đóng băng: CLIP, LLaVA, BERT · học: P_I , P_T · cổng: không tham số

Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

RHF · Tầng 2: trộn ba mô thức theo quan hệ

$$\alpha_m = \langle e_m, r \rangle + (1/3) \sum_j \langle e_m, e_j \rangle \quad (2)$$

$$w_m = \text{softmax}(\alpha_m - \bar{\alpha}) \quad H_{\text{joint}} = \sum_m w_m \cdot e_m \quad (3), (4)$$


$\langle e_m, r \rangle$ mô thức m hợp với quan hệ r bao nhiêu → **đổi theo r**

tb $\langle e_m, e_j \rangle$ m nhất quán với hai mô thức kia không → lọc mô thức thiếu / bịa

w_m ba tỉ lệ, tổng = 1, đổi theo **cả node lẫn quan hệ**

H_{joint} vector node cho câu hỏi này

Gwen Stefani, r = voice type




Tỉ lệ minh họa theo [1, Fig. 4]. Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Cùng node, đổi $r \rightarrow \langle e_m, r \rangle$ đổi → tỉ lệ đảo. Không có ma trận học riêng: "attention" với query = r, key = e_m trần.

MER: MLLM đoán đáp án, cổng quyết định tin bao nhiêu

- 1 **Prompt** = phần cố định (nhiệm vụ, định dạng) + text của h, láng giềng của h (bằng tên), ảnh h, quan hệ r → **LLaVA** + **LoRA**^a → một tên: "*Mezzo-soprano*" (5)
- 2 Tên → BERT → chiều → **T_MLLM** (2d số). Chỉ làm **một lần** mỗi câu hỏi.
- 3 Cổng: $g = \sigma(W_2 \cdot \tanh(W_1 \cdot T_{\text{MLLM}} + b_1) + b_2) \in (0,1)^{\{2d\}}$ — MLP $2d \rightarrow d \rightarrow 2d$, **có tham số học** (7)
- 4 Với **mỗi** ứng viên t: $\tilde{T}(t) = (1 - g) \circ T_{\text{joint}}(t) + g \circ T_{\text{MLLM}}$, tách phần thực / ảo (8–9)




g không nhìn ứng viên. LLaVA sai thì mọi ứng viên bị kéo về cùng chỗ sai; cổng chỉ học "đáp án trông đáng tin không", không học "hợp câu hỏi không".

Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Chấm điểm bằng RotatE: quan hệ là phép xoay

$$r_C = \cos(r/(\gamma/\pi)) + i \cdot \sin(r/(\gamma/\pi)) \quad \text{score} = -\| H_joint \circ r_C - \tilde{T} \| \quad (6), (10)$$



Một mặt phẳng phức trong d mặt phẳng. Hình tự vẽ, nguồn:

<https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Vì sao RotatE [2]: một phép xoay biểu diễn được đối xứng ($\theta = \pi$), nghịch đảo ($-\theta$), hợp thành ($\theta_1 + \theta_2$). Cài đặt bằng 2d số thực, không cần kiểu số phức.

- r_C r đổi thành d góc; mô-đun 1 $\rightarrow$ chỉ xoay, không co giãn
- $H \circ r_C$ xoay head trên từng mặt phẳng $\rightarrow$ điểm neo, tính 1 lần
- $\tilde{T}$ ứng viên sau cổng; đo 15 000 lần
- $\|\cdot\|$ khoảng cách gộp mọi mặt phẳng; gần $\rightarrow$ điểm cao
- γ thang đổi r sang góc

MNO: mẫu sai khó và huấn luyện đối kháng

Text giả

LLaVA viết lại mô tả: "American singer..." → "US-based vocalist..." → BERT → chiếu.


Ảnh giả (11)

$$\hat{\mathbf{e}}_v = ((1 - \lambda) \mathbf{I} + \lambda \mathbf{R}) \cdot \mathbf{x}_v + \epsilon$$

R ma trận xoay (QR của ma trận ngẫu nhiên hạng thấp)

λ $0 \rightarrow 1$ tăng theo epoch: dễ trước, khó sau

ϵ nhiễu Gauss



$L_D = L_{kgc} + \text{gradient penalty (14), tối ưu xen kẽ}$

Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

L_{kgc} loss self-adversarial của RotatE [2]: mẫu sai điểm cao bị phạt nặng hơn (12)


c ngưỡng: mẫu giả dưới c thì generator bị phạt

GP ép $\|\nabla D\| \approx 1$ để GAN ổn định^a

Mẫu "giả" với λ nhỏ gần như vẫn là node thật. Bài không kiểm chứng chúng có sai thật không.

[1] Eq. 11–14. [2] RotatE. ^a I. Gulrajani et al., "Improved training of Wasserstein GANs," NeurIPS 2017.

Luồng dữ liệu cho một truy vấn (h, r, ?)



Hình tự vẽ, nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>. Lúc train: thêm mẫu sai (MNO), tính loss, cập nhật E, R, P_m, cổng, LoRA.

Dữ liệu và độ đo

Dataset	Nguồn	#Entity	#Rel	#Train	#Valid	#Test	có ảnh	có text
MKG-W	Wikidata ^a	15 000	169	34 196	4 276	4 274	96%	94%
MKG-Y	YAGO ^a	15 000	28	21 310	2 665	2 663	95%	82%
DB15K	DBpedia ^b	12 842	279	79 222	9 902	9 904	99.8%	71%

Tỉ lệ có ảnh / text tự tính từ [1, Table 2]. DB15K thiếu text nhiều nhất; MKG-Y chỉ 28 quan hệ nên cấu trúc đã mạnh.

MRR

Trung bình 1/hạng của đáp án đúng. Hạng 1 → 1.0, hạng 10 → 0.1.


Hits@K

Tỉ lệ đáp án đúng nằm trong top K. Hits@1 khó nhất, Hits@10 dễ nhất.

Mỗi bộ ba test hỏi cả hai chiều (đoán tail, đoán head), lọc các đáp án đúng khác (filtered). 14 baseline được tác giả chạy lại với cùng CLIP/BERT.

^a D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022. ^b Y. Liu et al., "MMKG: multi-modal knowledge graphs," ESWC 2019.

Kết quả chính (MRR, %)



Vẽ lại từ [1, Table 1]. Nguồn hình: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>

Hơn baseline tốt nhất (NativeE): **+1.83** MKG-W, **+0.66** MKG-Y, **+1.61** DB15K.
Đứng đầu **11/12** ô (MRR, Hits@1/3/10 × 3 tập).

Ngoại lệ bài không nhấn: Hits@1 trên DB15K 23.04
thua RSME 24.45, APKGC 24.39, MyGO 24.19.

LLaVA thuần (prompt, không hàm điểm): Hits@10 chỉ 26% trên MKG-W, 3.6% trên MKG-Y.

Ablation trên MKG-W: mô-đun nào đáng tiền?



MRR. Vẽ lại từ [1, Table 3]. Nguồn hình: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>


RHF đóng góp lớn nhất trong 4 mô-đun: Hits@1 rớt 31.4 → 20.8 nhưng Hits@10 gần giữ nguyên → trộn theo quan hệ chủ yếu giúp **xếp đúng hạng 1**.

Cấu trúc vẫn là mô thức quan trọng nhất (−13). Text (−9) hơn ảnh (−7.5).

Caption do LLaVA sinh có ích thật (−6.8 khi bỏ).

Ablation chỉ làm trên MKG-W, không kiểm tra hai tập kia.

Case study: trọng số đối theo quan hệ



Nguồn: [1], Fig. 4

Không có RHF (trọng số ngẫu nhiên): ảnh được nghe nhiều nhất dù chỉ có ngoại hình → Mezzo-soprano **hạng 2**.

Có RHF: text lên, ảnh xuống → **hạng 1**.

Đây là ví dụ input-output ở slide 3, khép lại vòng: cùng ba vector, khác tỉ lệ pha, khác kết quả.

Nhận xét và hạn chế

Chi phí

LLaVA-7B chạy cho mỗi ảnh (caption), mỗi truy vấn (đoán), mỗi text (viết lại). Không báo cáo thời gian.

Tái lập

Không công khai code. Nhiều baseline do tác giả tự chạy lại.

Cải thiện không đều

MKG-Y chỉ +0.66. Thua Hits@1 trên DB15K. Ablation một tập.

Cổng G mù ngữ cảnh

g chỉ nhìn đáp án LLaVA, không nhìn câu hỏi. Không phân tích g hay tỉ lệ LLaVA đoán đúng.

Mẫu giả có sai thật?

Paraphrase "cùng nghĩa" và ảnh xoay nhẹ vẫn là node thật. Ngược hướng contrastive của MDBGF.

Căn chỉnh gián tiếp

Tích vô hướng giữa CLIP và BERT chỉ có nghĩa nhờ lớp chiếu học qua loss KGC; không có loss căn chỉnh riêng.

Thiếu chi tiết: prompt, epoch LoRA, cách chọn láng giềng, γ , c , τ , μ_1 , có chuẩn hoá vector trước tích vô hướng hay không.

Kết luận

- **Ý chính:** trọng số trộn mô thức phải phụ thuộc quan hệ đang hỏi. Cùng node, khác câu hỏi, khác vector.
- **Cách làm:** giữ RotatE làm hàm điểm, thay vector đầu vào bằng vector đã trộn ba mô thức theo r , cộng gợi ý của MLLM qua cổng, và train với mẫu sai khó.
- **Bằng chứng:** +1.8 MRR trên MKG-W; RHF là mô-đun đóng góp nhiều nhất; cấu trúc vẫn là mô thức quan trọng nhất.
- **Còn mở:** chi phí MLLM, cổng không nhìn câu hỏi, mẫu giả chưa chắc sai, không có code.

Một câu: **HFR-MKGC = RotatE + trộn mô thức có dẫn hướng bởi quan hệ + LLaVA làm cố vấn có kiểm soát + GAN nhỏ tạo mẫu sai.**

Tài liệu tham khảo

- [1] D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, and H. Li, "HFR-MKGC: Hierarchical Fusion Reasoning with MLLMs for Multi-modal Knowledge Graph Completion," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 18, 2026, pp. 15815–15823.
- [2] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge graph embedding by relational rotation in complex space," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019.
- [3] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 36, 2023, pp. 34892–34916.

Nguồn dùng một lần (đã ghi footnote tại slide)

A. Radford et al., "Learning transferable visual models from natural language supervision," ICML 2021 · J. Devlin et al., "BERT: Pre-training of deep bidirectional transformers," NAACL 2019 · E. J. Hu et al., "LoRA," ICLR 2022 · I. Gulrajani et al., "Improved training of Wasserstein GANs," NeurIPS 2017 · D. Xu et al., "Relation-enhanced negative sampling for multimodal KGC," ACM MM 2022 · Y. Liu et al., "MMKG," ESWC 2019 · Y. Zhang et al., "Native," SIGIR 2024.

Nguồn hình

Fig. 1, 2, 4: cắt từ PDF của [1]. Các hình còn lại do nhóm vẽ với sự hỗ trợ của AI (Claude), nguồn: <https://claude.ai/code/artifact/79ab1978-2487-4ea1-9077-c9996e7cbef2>