# Hoàn thiện đồ thị tri thức đa phương thức: tìm hiểu hai công trình HFR-MKGC và MDBGF

Nguyễn Đình Lộc (25C11050) Ngô Trương Minh Đạt (25C15003)
Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM
Học phần: Học máy với dữ liệu đồ thị Giảng viên: TS. Lê Ngọc Thành

***Tóm tắt nội dung*—Báo cáo này trình bày cách hiểu của nhóm về hai công trình gần đây trong bài toán hoàn thiện đồ thị tri thức đa phương thức (Multi-modal Knowledge Graph Completion, MMKGC). Phần thứ nhất phân tích HFR-MKGC (AAAI 2026), một khung kết hợp ba ý tưởng trên nền hàm điểm RotatE: trộn ba mô thức của thực thể với trọng số phụ thuộc quan hệ đang xét, đưa dự đoán của một mô hình ngôn ngữ lớn đa phương thức vào hàm điểm thông qua một cổng học được, và huấn luyện đối kháng với mẫu âm sinh bằng cách bóp méo đặc trưng ảnh và văn bản. Nhóm diễn giải lại từng mô-đun bằng một ví dụ chạy tay xuyên suốt, tổng hợp kết quả thực nghiệm trên ba bộ dữ liệu chuẩn và chỉ ra các điểm chưa thuyết phục của bài báo. Phần thứ hai phân tích MDBGF (Findings of ACL 2026), tiếp cận bài toán theo hướng ngược lại: chủ động làm rụng ảnh hoặc văn bản khi huấn luyện, dùng hai cổng để ảnh và văn bản điều chỉnh lẫn nhau, và bổ sung mẫu âm khó theo lịch tăng dần. Nhóm đối chiếu bài báo với mã nguồn công khai của tác giả và chỉ ra một số điểm không khớp. Phần cuối đối chiếu hai hướng tiếp cận và rút ra bài học chung.**

***Từ khoá*—đồ thị tri thức, hoàn thiện đồ thị tri thức, học biểu diễn đa phương thức, mô hình ngôn ngữ lớn đa phương thức, huấn luyện đối kháng**

## I. Giới thiệu chung

### A. Bài toán

Một đồ thị tri thức (Knowledge Graph, KG) lưu sự thật dưới dạng bộ ba $(h, r, t)$: thực thể đầu $h$, quan hệ $r$ và thực thể đuôi $t$. Ví dụ (Gwen Stefani, voice type, Mezzo-soprano). KG xây dựng tự động hay bán tự động luôn thiếu cạnh, nên bài toán hoàn thiện đồ thị tri thức (Knowledge Graph Completion, KGC) đặt câu hỏi: cho $(h, r, ?)$ hoặc $(?, r, t)$, thực thể nào điền vào chỗ trống là hợp lý nhất. Đây là bài toán dự đoán liên kết, không phải sinh thực thể mới: đáp án luôn là một node đã có trong đồ thị.

Trong KG đa phương thức (Multi-modal KG, MMKG), mỗi thực thể ngoài vị trí trong đồ thị còn có một đoạn mô tả văn bản và một hoặc nhiều ảnh. Trong báo cáo này, mỗi loại dữ liệu gắn với thực thể (cấu trúc, ảnh, văn bản) được gọi là một *mô thức* (modality); đồ thị mà thực thể có nhiều mô thức như vậy gọi là đồ thị *đa phương thức*. MMKGC là KGC trên dữ liệu đó. Câu hỏi trung tâm của cả hai bài báo trong báo cáo này là: dùng văn bản và ảnh thế nào để chúng giúp dự đoán thay vì gây nhiễu, nhất là khi một phần thực thể thiếu ảnh hoặc thiếu mô tả.

Theo thuật ngữ của môn học, hai bài báo đều thuộc nhóm nhúng đồ thị tri thức (Knowledge Graph Embedding, KGE): mỗi thực thể và mỗi quan hệ là một hàng trong bảng tham số, không có bước truyền tin giữa các node như mạng nơ-ron đồ thị (GNN). Cấu trúc đồ thị đi vào mô hình qua hàm mất mát: mỗi cạnh trong tập huấn luyện là một ràng buộc buộc vector của $h$, $r$, $t$ phải khớp nhau theo một hàm điểm. Vì không có phép gom láng giềng, câu hỏi về bất biến hoán vị không phát sinh.

Bảng I
Ba bộ dữ liệu MMKGC dùng trong cả hai bài báo. Số liệu theo [3]; hai cột cuối do nhóm tính.

| Bộ dữ liệu | #Ent | #Rel | #Train | #Valid | #Test | Có ảnh | Có văn bản |
|---|---|---|---|---|---|---|---|
| MKG-W | 15000 | 169 | 34196 | 4276 | 4274 | 96,4% | 94,2% |
| MKG-Y | 15000 | 28 | 21310 | 2665 | 2663 | 95,0% | 82,0% |
| DB15K | 12842 | 279 | 79222 | 9902 | 9904 | 99,8% | 70,7% |

### B. Cách đánh giá chung

Với mỗi bộ ba kiểm thử, mô hình che một đầu, chấm điểm toàn bộ thực thể làm ứng viên và xếp hạng. Đáp án đúng đứng hạng càng cao càng tốt. Hai độ đo được dùng: MRR (trung bình nghịch đảo hạng) và Hits@$K$ (tỉ lệ đáp án đúng nằm trong $K$ hạng đầu). Cả hai bài đều dùng thiết lập lọc (filtered): các đáp án đúng khác đã có trong KG bị loại khỏi danh sách xếp hạng để không bị phạt oan. Cả hai chiều $(h, r, ?)$ và $(?, r, t)$ đều được hỏi.

Ba bộ dữ liệu chuẩn xuất hiện trong cả hai bài: MKG-W và MKG-Y [1] (trích từ Wikidata và YAGO), DB15K [2] (trích từ DBpedia). Thống kê ở Bảng I; hai cột cuối là tỉ lệ thực thể có ảnh và có văn bản, nhóm tự tính từ số liệu gốc. Điểm đáng chú ý là DB15K thiếu văn bản ở gần 30% thực thể, còn MKG-Y chỉ có 28 quan hệ nên cấu trúc đã rất giàu thông tin.

### C. Cấu trúc báo cáo

Phần II dành cho HFR-MKGC [3], bài nhóm đã trình bày seminar. Phần III dành cho MDBGF [4]. Phần IV đối chiếu hai bài và kết luận. Mọi số liệu thực nghiệm được lấy từ bài báo gốc và ghi rõ nguồn; nhóm không chạy lại thực nghiệm của HFR-MKGC vì tác giả không công khai mã nguồn.

## II. Phần A: HFR-MKGC

### A. Động lực và ý tưởng chính

Để thấy vì sao cần đa mô thức, hãy lấy truy vấn xuyên suốt của báo cáo: (Gwen Stefani, voice type, ?). Trong MKG-W, thực thể này chỉ có một cạnh huấn luyện là field of work → music. Nếu chỉ nhìn cấu trúc, gần như không có căn cứ để chọn giữa Mezzo-soprano, Soprano hay hàng nghìn node khác.

Đoạn mô tả có chữ "singer" và ảnh chân dung mới là thứ gợi ý rằng đáp án phải là một loại giọng hát.

Từ góc nhìn của nhóm, bài báo chỉ ra hai điểm yếu của các phương pháp trước và đề xuất một cách sửa cho mỗi điểm:

1) **Trọng số trộn mô thức không phụ thuộc câu hỏi.** Các mô hình như RSME [5] hay NativE [6] trộn cấu trúc, ảnh, văn bản bằng cổng hoặc chú ý, nhưng tỉ lệ trộn của một thực thể là cố định hoặc chỉ phụ thuộc chính thực thể đó. Với Gwen Stefani, ảnh hữu ích khi hỏi giới tính nhưng vô ích khi hỏi loại giọng; một bộ trọng số không thể đúng cho cả hai câu hỏi. HFR-MKGC đưa vector quan hệ vào công thức tính trọng số, nên cùng một thực thể có tỉ lệ trộn khác nhau tuỳ quan hệ đang xét.
2) **Mô hình ngôn ngữ lớn (LLM) được dùng thô.** Các phương pháp dựa trên LLM biến đồ thị thành prompt rồi để LLM trả lời, nhưng LLM không biết ranh giới tập thực thể, hay bịa tên, và không chấm điểm được toàn bộ ứng viên. Bảng III xác nhận điều đó: LLaVA chạy một mình chỉ đạt Hits@10 bằng 26,42% trên MKG-W và 3,58% trên MKG-Y. HFR-MKGC không cho LLM làm bộ chấm điểm mà coi câu trả lời của nó là một gợi ý, đưa vào hàm điểm RotatE qua một cổng có thể học mức tin cậy.

Ý thứ ba của bài là về huấn luyện: mẫu âm thay ngẫu nhiên thực thể đuôi quá dễ phân biệt, nên tác giả sinh thêm mẫu âm "khó" bằng cách giữ nguyên thực thể nhưng bóp méo đặc trưng ảnh và văn bản, rồi huấn luyện theo kiểu đối kháng.

Tên bài gói ba ý này thành ba mô-đun: RHF (Relation-guided Hierarchical Fusion, hợp nhất phân cấp có dẫn hướng bởi quan hệ), MER (MLLM-Enhanced Reasoning, suy luận tăng cường bằng MLLM) và MNO (Multi-modal Noise Optimization, tối ưu nhiễu đa mô thức). Hình 1 là sơ đồ của tác giả; Hình 2 là sơ đồ nhóm vẽ lại theo luồng dữ liệu của một truy vấn, dùng làm xương sống cho các mục sau.

### B. Biểu diễn thực thể và quan hệ

Mỗi thực thể $e$ được lưu bằng *ba* vector cùng chiều $d$, mỗi vector ứng với một mô thức $m \in \{S, I, T\}$:

- $\mathbf{e}_S$ (cấu trúc): một hàng trong bảng tham số $\mathbf{E} \in \mathbb{R}^{|\mathcal{E}| \times d}$, khởi tạo ngẫu nhiên, học từ đầu cùng toàn mô hình. Không có bước tiền huấn luyện riêng.
- $\mathbf{e}_T$ (văn bản): đoạn mô tả qua BERT [7] đóng băng, rồi qua một lớp chiếu học được $P_T$ để về chiều $d$.
- $\mathbf{e}_I$ (ảnh): ảnh qua CLIP [8] đóng băng rồi qua lớp chiếu $P_I$. Riêng mô thức này còn có một nhánh thứ hai mô tả ở Mục II-C.

Quan hệ $r$ chỉ có *một* vector $\mathbf{r} \in \mathbb{R}^d$, cũng khởi tạo ngẫu nhiên và học từ đầu; quan hệ không có ảnh hay văn bản. Vector này được dùng ở ba chỗ: làm "câu hỏi" khi tính trọng số trộn (Mục II-D), làm góc xoay trong RotatE (Mục II-F), và tên quan hệ dạng chữ được chèn vào prompt cho LLaVA (Mục II-E).

Vì CLIP và BERT xuất ra không gian khác nhau (512 và 768 chiều cho các bản thường dùng), hai lớp chiếu $P_I$, $P_T$ là chỗ duy nhất đưa chúng về cùng một không gian. Bài báo không có hàm mất mát căn chỉnh riêng cho việc này; hai lớp chiếu học gián tiếp qua hàm mất mát KGC cuối cùng. Nhóm quay lại điểm này ở Mục II-J.

### C. RHF tầng 1: gộp hai cách nhìn một tấm ảnh

Tầng 1 chỉ làm việc với ảnh, vì ảnh được mã hoá theo hai cách. Nhánh thị giác cho vector $\mathbf{e}_{I_v} = P_I(\text{CLIP}(\text{ảnh}))$. Nhánh ngữ nghĩa cho LLaVA [9] viết một câu mô tả ảnh (caption, ví dụ "a woman singing on stage"), rồi câu đó qua BERT và $P_T$ thành $\mathbf{e}_{I_c}$. Hai vector nói về cùng một tấm ảnh nhưng ở hai dạng: một dạng là đặc trưng thị giác thô, một dạng đã được dịch sang ngôn ngữ, gần với thế giới của KG hơn.

Cách gộp là một cổng không có tham số:

$$\sigma = \text{sigmoid}\big(\langle \mathbf{e}_{I_v}, \mathbf{e}_{I_c} \rangle\big), \qquad \mathbf{e}_I = \sigma\, \mathbf{e}_{I_c} + (1 - \sigma)\, \mathbf{e}_{I_v}. \quad (1)$$

Tích vô hướng đo hai cách nhìn có khớp nhau không. Khớp cao thì $\sigma$ gần 1, tin caption nhiều hơn; khớp thấp nghĩa là caption có thể tả sai, giữ đặc trưng CLIP. Quy ước "caption nhận $\sigma$, CLIP nhận $1 - \sigma$" là do tác giả cố định; nếu đảo lại mô hình vẫn học được vì không có tham số nào gắn với quy ước đó, nhưng ý đồ "khi hai bên đồng ý thì ưu tiên dạng ngôn ngữ" là lý do chọn chiều này.

Bản thân tầng này không có tham số nào để học. Tham số học nằm ở $P_I$ và $P_T$; chúng phải tự xoay hai không gian sao cho tích vô hướng ở (1) có nghĩa, và động lực duy nhất để làm vậy là hàm mất mát KGC ở cuối.

### D. RHF tầng 2: trộn ba mô thức theo quan hệ

Đây là mô-đun quan trọng nhất và cũng là chữ "relation-guided" trong tên bài. Cho thực thể $e$ với ba vector $\mathbf{e}_S, \mathbf{e}_I, \mathbf{e}_T$ và quan hệ $\mathbf{r}$, mỗi mô thức $m$ nhận một điểm thô:

$$\alpha_m = \underbrace{\langle \mathbf{e}_m, \mathbf{r} \rangle}_{\text{liên quan tới câu hỏi}} + \underbrace{\frac{1}{3} \sum_{j \in \{S,I,T\}} \langle \mathbf{e}_m, \mathbf{e}_j \rangle}_{\text{nhất quán với hai mô thức kia}}. \quad (2)$$

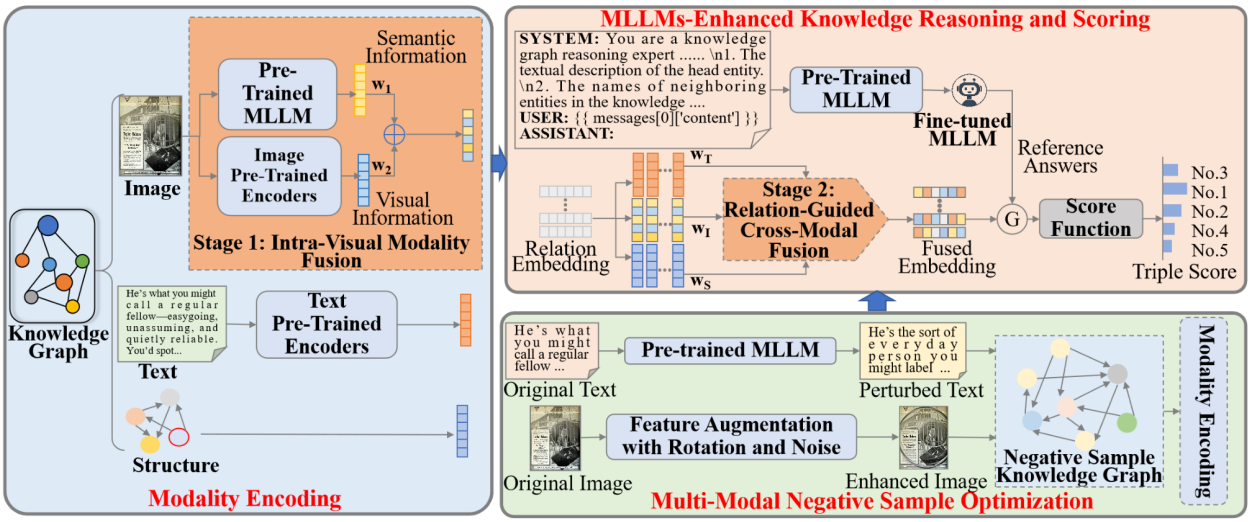
Số hạng thứ nhất là chỗ làm trọng số đổi theo quan hệ: cùng $\mathbf{e}_I$ nhưng tích với vector của voice type khác tích với vector của place of birth. Số hạng thứ hai lấy trung bình độ tương đồng với các mô thức của chính thực thể (gồm cả với chính nó), để hạ điểm những mô thức lạc lõng, ví dụ ảnh mặc định do thiếu dữ liệu hoặc mô tả bị bịa.

Ba điểm thô qua softmax thành ba tỉ lệ cộng bằng 1, rồi pha ba vector theo tỉ lệ đó:

$$w_m = \frac{\exp(\alpha_m)}{\sum_j \exp(\alpha_j)}, \qquad \mathbf{H}_{\text{joint}} = \sum_m w_m\, \mathbf{e}_m. \quad (3)$$

Softmax ở đây chạy trên *ba con số*, không phải trên ba vector; mỗi mô thức nhận đúng một trọng số dùng chung cho mọi chiều.

*a) Ví dụ chạy tay.:* Để thấy cơ chế, nhóm chọn $d = 3$ với các số tự đặt (không phải số của bài báo): $\mathbf{e}_S = [0{,}5;\ 0{,}1;\ -0{,}3]$, $\mathbf{e}_I = [0{,}8;\ 0{,}7;\ 0{,}1]$, $\mathbf{e}_T = [-0{,}1;\ 0{,}9;\ 0{,}6]$, $\mathbf{r} = [-0{,}2;\ 1{,}0;\ 0{,}5]$. Số hạng thứ nhất của (2) cho $-0{,}15$, 0,59, 1,22; số hạng thứ hai cho 0,22, 0,73, 0,55. Cộng lại $\alpha = [0{,}07;\ 1{,}32;\ 1{,}77]$, softmax cho $w = [0{,}10;\ 0{,}35;\ 0{,}55]$ và $\mathbf{H}_{\text{joint}} = [0{,}275;\ 0{,}750;\ 0{,}335]$. Nếu bỏ số hạng chứa $\mathbf{r}$,




Hình 1. Kiến trúc HFR-MKGC theo hình gốc của tác giả (Hình 2 trong [3]). Bên trái: mã hoá ba mô thức và tầng 1 của RHF. Phải trên: tầng 2 của RHF, suy luận bằng MLLM và cổng $G$ trước hàm điểm. Phải dưới: sinh mẫu âm trong MNO.

trọng số thành [0,24; 0,41; 0,35]: ảnh lên cao nhất, văn bản rớt xuống. Hình 3 vẽ hai bộ trọng số này. Đó chính là khác biệt giữa HFR-MKGC và các mô hình trộn không nhìn quan hệ: cùng một thực thể, đổi câu hỏi thì tỉ lệ đổi theo, nhưng số tham số không tăng vì cái được lưu vẫn chỉ là ba vector.

Về bản chất, (2)–(3) là một phép chú ý (attention) rút gọn: truy vấn là chính $\mathbf{r}$, khoá và giá trị là chính các vector mô thức, không có ma trận chiếu $W_Q, W_K, W_V$. Cách thiết kế này giữ tầng 2 không có tham số, giống tầng 1.

### *E. MER: cho LLaVA gợi ý, nhưng không cho nó chấm điểm*

Mô-đun MER đưa mô hình ngôn ngữ lớn đa phương thức LLaVA-1.5-7B vào vòng lặp theo bốn bước.

**Bước 1, hỏi.** Với mỗi truy vấn $(h, r, ?)$, ghép một prompt gồm phần hướng dẫn cố định, đoạn mô tả của $h$, tên các láng giềng của $h$ trong đồ thị, ảnh của $h$ và tên quan hệ $r$ dạng chữ. LLaVA được tinh chỉnh bằng LoRA [10] cho đúng nhiệm vụ này; phần nối CLIP với mô hình ngôn ngữ bên trong LLaVA là có sẵn từ dự án LLaVA, tác giả chỉ thêm các ma trận hạng thấp. Đầu ra là *một chuỗi tên*, ví dụ "Mezzo-soprano".

**Bước 2, mã hoá.** Chuỗi đó qua BERT và lớp chiếu thành vector $\mathbf{T}_{\text{MLLM}} \in \mathbb{R}^{2d}$ (chiều $2d$ vì hàm điểm RotatE làm việc với $d$ số phức, xem Mục II-F). Mỗi truy vấn chỉ tính $\mathbf{T}_{\text{MLLM}}$ một lần.

**Bước 3, cổng.** Một mạng hai lớp đọc $\mathbf{T}_{\text{MLLM}}$ và xuất ra mức tin cậy theo từng chiều:

$$\mathbf{g} = \text{sigmoid}\big(W_2 \tanh(W_1 \mathbf{T}_{\text{MLLM}} + \mathbf{b}_1) + \mathbf{b}_2\big) \in (0,1)^{2d}, \quad (4)$$

với $W_1 \in \mathbb{R}^{d \times 2d}$, $W_2 \in \mathbb{R}^{2d \times d}$. Đây là chỗ *có* tham số học, khác hai cổng không tham số ở RHF.

**Bước 4, kéo ứng viên về phía gợi ý.** Với mỗi ứng viên đuôi $t$, trước hết tính $\mathbf{T}_{\text{joint}}(t)$ bằng đúng hàm RHF hai tầng ở trên (cùng vector $\mathbf{r}$), rồi pha với gợi ý theo từng chiều:

$$\tilde{\mathbf{T}}(t) = (\mathbf{1} - \mathbf{g}) \odot \mathbf{T}_{\text{joint}}(t) + \mathbf{g} \odot \mathbf{T}_{\text{MLLM}}. \quad (5)$$

Mọi ứng viên bị dịch một đoạn về phía $\mathbf{T}_{\text{MLLM}}$; ứng viên nào vốn đã gần gợi ý thì sau khi dịch càng gần điểm neo của RotatE. Nếu $\mathbf{g}$ gần 0, mô hình bỏ qua LLaVA và quay về RotatE thuần. Thực thể đầu không bị kéo; bài báo có nhắc tới $\tilde{\mathbf{H}}_{\text{joint}}$ nhưng không định nghĩa, nên nhóm hiểu là thực thể đầu dùng thẳng $\mathbf{H}_{\text{joint}}$.

Chỗ nhóm thấy chưa ổn là $\mathbf{g}$ chỉ nhìn $\mathbf{T}_{\text{MLLM}}$, không nhìn $\mathbf{H}_{\text{joint}}$ hay $\mathbf{r}$. Cổng do đó học "đáp án kiểu này đáng tin bao nhiêu" chứ không học "đáp án này có hợp với câu hỏi này không". Nếu LLaVA trả về một tên có thật nhưng sai quan hệ, cổng khó phát hiện.

### *F. Hàm điểm RotatE*

HFR-MKGC không đề xuất hàm điểm mới mà dùng RotatE [11], chỉ thay đầu vào bằng các vector đã trộn. Trong RotatE, mỗi thực thể là một vector $d$ số phức, lưu bằng $2d$ số thực (nửa đầu phần thực, nửa sau phần ảo), tức $d$ điểm trên $d$ mặt phẳng độc lập. Quan hệ là $d$ góc xoay $\theta_k$, lấy từ vector $\mathbf{r}$ bằng cách chia cho một hằng số $\gamma$ và nhân $\pi$, rồi đổi thành số phức mô-đun 1:

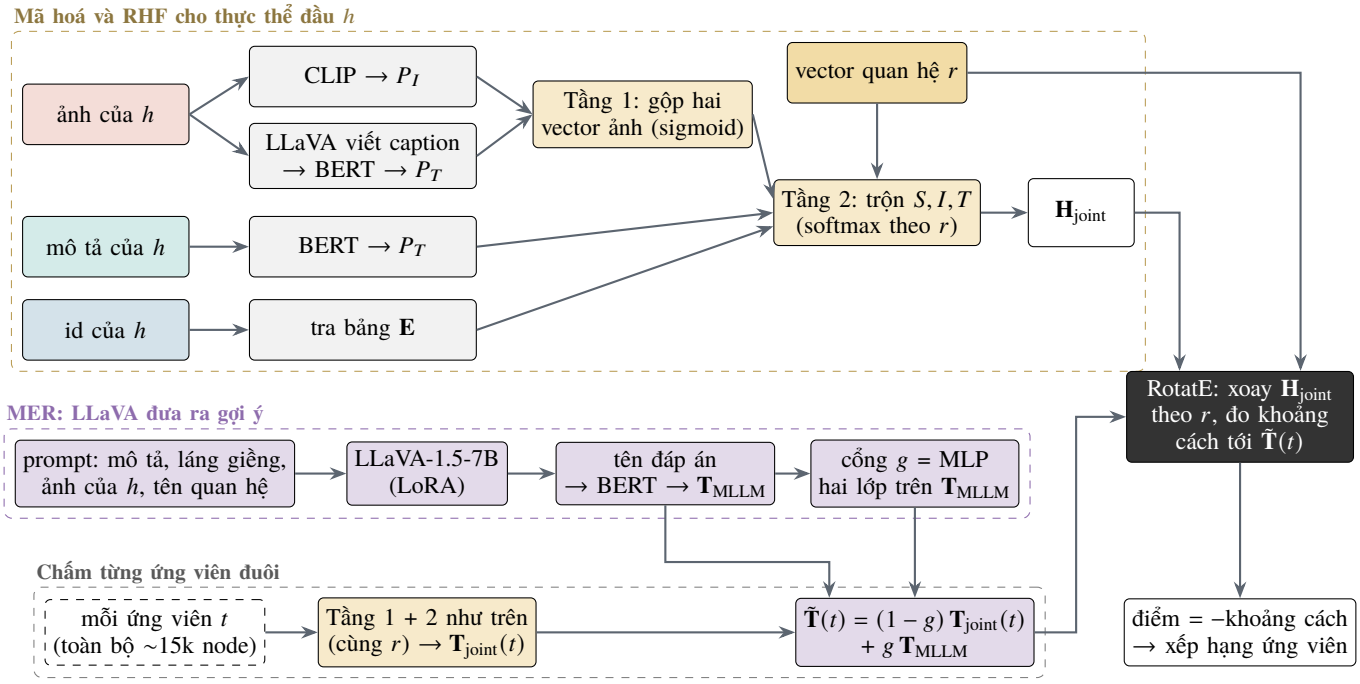
$$\theta_k = \pi \frac{r_k}{\gamma}, \qquad r_k^{\mathbb{C}} = \cos\theta_k + i \sin\theta_k. \quad (6)$$

Điểm của một bộ ba là âm khoảng cách giữa thực thể đầu sau khi xoay và thực thể đuôi:

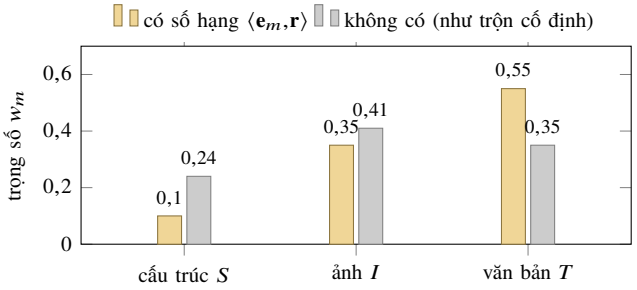
$$f(h, r, t) = -\big\|\mathbf{H}_{\text{joint}} \circ \mathbf{r}^{\mathbb{C}} - \tilde{\mathbf{T}}(t)\big\|, \quad (7)$$

trong đó $\circ$ là nhân từng phần tử trên số phức, tức xoay điểm thứ $k$ một góc $\theta_k$ trên mặt phẳng thứ $k$ (Hình 4). Trên số thực, phép xoay là $a' = a\cos\theta - b\sin\theta$, $b' = a\sin\theta + b\cos\theta$, nên cài đặt không cần kiểu dữ liệu phức.

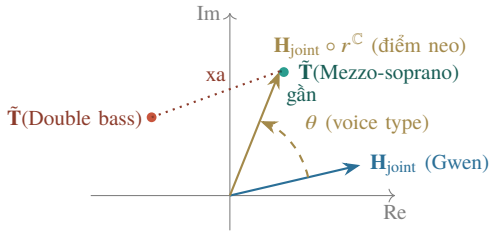
Lý do giữ RotatE: một phép xoay mô tả được ba kiểu quan hệ thường gặp. Quan hệ đối xứng ứng với góc $180^\circ$ (xoay hai lần trở về chỗ cũ), quan hệ nghịch đảo ứng với góc đối $-\theta$, và quan hệ hợp thành ứng với cộng góc $\theta_1 + \theta_2$. Việc biểu diễn trong không gian phức không phải điểm mới của bài; nó kế




Hình 2. Luồng dữ liệu của một truy vấn $(h, r, ?)$ trong HFR-MKGC, nhóm vẽ lại từ mô tả trong [3]. Mỗi ứng viên đuôi đi qua cùng hàm RHF rồi được kéo về phía gợi ý của LLaVA theo tỉ lệ $g$; RotatE chỉ xoay thực thể đầu một lần và đo khoảng cách tới từng ứng viên. Khi huấn luyện, luồng này giữ nguyên và thêm nhánh MNO sinh mẫu âm (Mục II-G).




Hình 3. Trọng số trộn ở tầng 2 trong ví dụ chạy tay ($d = 3$, số liệu nhóm tự đặt để minh hoạ). Có vector quan hệ, văn bản thắng; bỏ đi, ảnh thắng. Hình do nhóm vẽ.




Hình 4. RotatE trên một trong $d$ mặt phẳng phức: xoay thực thể đầu theo góc của quan hệ rồi đo khoảng cách tới từng ứng viên. Xoay chỉ làm một lần cho mỗi truy vấn; đo lặp lại cho mọi ứng viên. Hình do nhóm vẽ, minh hoạ ý tưởng, không theo số liệu thật.

thừa từ ComplEx [12] và RotatE. Đóng góp của HFR-MKGC nằm ở *thứ được đưa vào* hàm điểm: $\mathbf{H}_{\text{joint}}$ đã trộn theo $r$ và $\tilde{\mathbf{T}}$ đã được LLaVA kéo.

Tổng kết luồng suy diễn cho (Gwen Stefani, voice type, ?): mã hoá ba mô thức của Gwen, trộn theo quan hệ voice type ra $\mathbf{H}_{\text{joint}}$, xoay theo $d$ góc của voice type ra điểm neo; song song, LLaVA trả lời "Mezzo-soprano", mã hoá thành $\mathbf{T}_{\text{MLLM}}$ và tính $\mathbf{g}$; với từng ứng viên trong 15000 thực thể, tính $\mathbf{T}_{\text{joint}}$ rồi $\tilde{\mathbf{T}}$, đo khoảng cách tới điểm neo, xếp hạng. Không có ngưỡng "có cạnh hay không"; kết quả là một thứ hạng. Đáp án của LLaVA chỉ dịch chuyển các ứng viên, không bao giờ là đáp án cuối.

### *G. MNO: mẫu âm khó và huấn luyện đối kháng*

Huấn luyện KGE cần mẫu âm. Cách thường dùng là thay $t$ bằng một thực thể ngẫu nhiên; mẫu như vậy quá dễ phân biệt nên tín hiệu học yếu dần. MNO giữ nguyên thực thể và bóp méo đặc trưng của nó theo hai cách:

- **Văn bản:** LLaVA viết lại đoạn mô tả theo cách khác (paraphrase), rồi mã hoá bằng BERT như thường.
- **Ảnh:** vector CLIP $\mathbf{x}$ được xoay và cộng nhiễu:

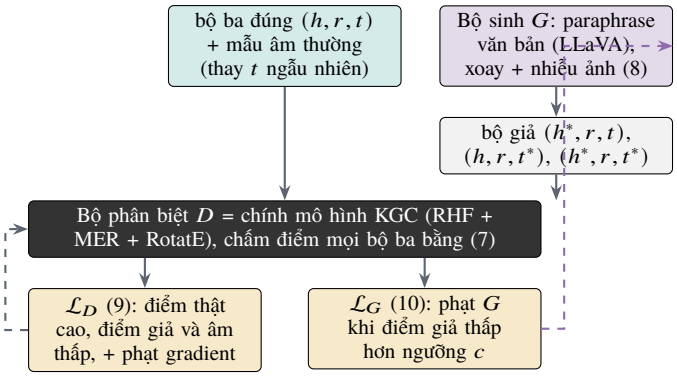
$$\hat{\mathbf{x}} = \big((1-\lambda)\mathbf{I} + \lambda\mathbf{R}\big)\mathbf{x} + \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \sigma^2\mathbf{I}), \tag{8}$$

với $\mathbf{R}$ là ma trận trực giao lấy từ phân rã QR của một ma trận hạng thấp, và $\lambda$ tăng tuyến tính theo epoch (mỗi epoch là một lượt duyệt hết tập huấn luyện): đầu khoá học mẫu giả gần bản gốc, cuối khoá học lệch xa hơn (curriculum).

Từ một bộ ba đúng $(h, r, t)$ sinh ba bộ giả $(h^*, r, t)$, $(h, r, t^*)$, $(h^*, r, t^*)$, trong đó dấu sao là bản bị bóp méo. Chúng được chấm bằng cùng hàm điểm (7).

Phần huấn luyện là một trò chơi hai bên (Hình 5). Bên "phân biệt" là chính mô hình KGC, tối thiểu hoá

$$\mathcal{L}_D = \mathcal{L}_{\text{kgc}} + \mu_1\,\mathcal{L}_{\text{gp}}, \tag{9}$$




Hình 5. Vòng huấn luyện đối kháng của MNO. Bộ phân biệt chính là mô hình KGC; hai hàm mất mát được tối ưu xen kẽ. Mũi tên đứt nét tím: cập nhật bộ sinh $G$; đứt nét xám: cập nhật $D$. Hình do nhóm vẽ.

Bảng II
THÀNH PHẦN HỌC ĐƯỢC VÀ ĐÓNG BĂNG TRONG HFR-MKGC (NHÓM TỔNG HỢP TỪ [3]).

| Thành phần | Trạng thái |
|---|---|
| Bảng thực thể **E**, bảng quan hệ **R** | học từ đầu |
| Lớp chiếu $P_I$, $P_T$ | học |
| Cổng **g** (MLP hai lớp) | học |
| LoRA trong LLaVA (nhiệm vụ đoán đáp án) | học |
| Cổng tầng 1, softmax tầng 2 | không có tham số |
| CLIP, BERT, phần còn lại của LLaVA | đóng băng |

trong đó $\mathcal{L}_{\text{kgc}}$ là hàm mất mát tự đối kháng của RotatE (mẫu âm khó hơn nhận trọng số softmax lớn hơn) tính trên cả mẫu âm thường và mẫu giả, còn $\mathcal{L}_{\text{gp}}$ là phạt gradient kiểu WGAN-GP [13] để ổn định. Bên "sinh" là bộ bóp méo, tối thiểu hoá

$$\mathcal{L}_G = \sum_k \max\big(0,\ c - f(\text{bộ giả}_k)\big), \tag{10}$$

tức bị phạt khi mẫu giả bị nhận ra quá dễ (điểm thấp hơn ngưỡng $c$). Hai bên cập nhật xen kẽ. Khung đối kháng này kế thừa từ AdaMF-MAT [14]; phần mới của bài là cách sinh mẫu giả bằng LLM và ma trận xoay.

Có điều, một đoạn văn "cùng nghĩa, khác lời" và một ảnh xoay nhẹ về bản chất vẫn là thực thể gốc. Bài coi chúng là bộ ba sai nhưng không kiểm chứng điều đó. Cách hiểu hợp lý hơn là hàm mất mát chỉ ép điểm của bản gốc cao hơn bản giả một chút, làm ranh giới quanh mỗi thực thể sắc hơn, thay vì thật sự dạy mô hình phân biệt đúng và sai. Đây cũng là chỗ MDBGF đi theo giả định ngược lại (Phần III).

### H. Những gì được học và không được học

Để tiện đối chiếu, Bảng II liệt kê tham số học và tham số đóng băng. Điều đáng chú ý là hai cổng của RHF đều không có tham số; toàn bộ sức "thích nghi theo quan hệ" đến từ việc bảng **E**, bảng **R** và hai lớp chiếu cùng học qua một hàm mất mát duy nhất.

### I. Thực nghiệm

*a) Thiết lập.:* Tác giả huấn luyện 250 epoch bằng Adam trên hai GPU RTX A6000, chọn chiều $d \in \{128, 256, 512\}$, số mẫu âm mỗi bộ ba trong $\{32, 64, 128\}$, tốc độ học trong $\{10^{-5}, 10^{-4}, 10^{-3}\}$ và kích thước batch (số bộ ba xử lý trong một bước cập nhật) trong $\{128, 256, 1024\}$. Vì nhiều mô hình cơ sở không công khai đủ mã hay dữ liệu, tác giả tự chạy lại chúng với cùng bộ mã hoá CLIP và BERT. Nhóm *không* tái lập được HFR-MKGC vì mã nguồn không công khai, nên mọi số liệu dưới đây là của bài báo.

*b) Kết quả chính.:* Bảng III rút gọn từ Bảng 1 của bài, giữ RotatE làm mốc, các mô hình MMKGC mạnh nhất và LLaVA chạy đơn độc. Ba quan sát:

1) So với mô hình cơ sở tốt nhất NativE, HFR-MKGC tăng MRR 1,83 điểm trên MKG-W và 1,61 điểm trên DB15K nhưng chỉ 0,66 điểm trên MKG-Y. MKG-Y có 28 quan hệ, cấu trúc đã đủ mạnh nên đa mô thức thêm được ít; điều này nhất quán với động lực của bài.
2) HFR-MKGC đứng đầu 11 trong 12 ô. Ngoại lệ là Hits@1 trên DB15K (23,04%), thua RSME, APKGC và MyGO. Bài viết rằng phương pháp đạt mức tốt nhất trên mọi độ đo; nhóm cho rằng cần nói chính xác là 11/12.
3) LLaVA dùng một mình kém xa mọi mô hình KGE, đặc biệt trên MKG-Y (Hits@10 bằng 3,58%). LLM không thay được hàm điểm có cấu trúc; vai trò hợp lý của nó là bổ trợ, đúng như cách MER thiết kế.

*c) Loại bỏ từng phần.:* Bảng IV là nghiên cứu loại bỏ, chỉ làm trên MKG-W. Nhóm đọc bảng này theo hai hướng.

Theo mô-đun: bỏ RHF (thay bằng trung bình cộng ba mô thức) mất nhiều nhất, 6,64 điểm MRR. Đáng chú ý là Hits@10 gần như không đổi (50,25 so với 51,66) trong khi Hits@1 rớt từ 31,37 xuống 20,80. Nghĩa là trộn theo quan hệ không giúp tìm thêm ứng viên vào top 10, mà giúp *xếp đúng ứng viên lên hạng nhất*. Bỏ MER mất 5,10 điểm, bỏ MNO mất 4,61 điểm; thay cách bóp méo của MNO bằng nhiễu ngẫu nhiên (dòng bỏ PTI) mất 4,03 điểm, cho thấy cách sinh mẫu giả có ý nghĩa chứ không chỉ là thêm nhiễu.

Theo mô thức: bỏ cấu trúc mất 12,95 điểm, vẫn là mô thức quan trọng nhất; bỏ văn bản mất nhiều hơn bỏ ảnh (8,95 so với 7,46); bỏ riêng caption do LLaVA sinh (dòng bỏ VT) mất 6,84 điểm, chứng tỏ tầng 1 của RHF có ích thật.

*d) Độ nhạy siêu tham số.:* Tác giả quét chiều $d$ và số mẫu âm trên MKG-W cho cả HFR-MKGC và RotatE. Kết luận có thể dùng được: chiều lớn (512) chỉ phát huy khi có nhiều mẫu âm (128); chiều 256 tốt nhất với 64 mẫu âm; chiều 128 gần như không nhạy với số mẫu âm. MRR và Hits@1 dao động mạnh hơn Hits@10, nhất quán với nhận xét ở phần loại bỏ rằng các mô-đun chủ yếu tác động lên thứ hạng đầu.

*e) Nghiên cứu tình huống.:* Hình 6 là ví dụ của tác giả với đúng truy vấn Gwen Stefani. Khi thay RHF bằng trọng số ngẫu nhiên, ảnh nhận trọng số cao nhất dù chỉ chứa ngoại hình, và Mezzo-soprano đứng hạng 2. Với RHF, trọng số văn bản tăng, ảnh giảm, đáp án đúng lên hạng 1. Đây là minh chứng định tính cho cơ chế ở Mục II-D.

### J. Nhận xét và hạn chế

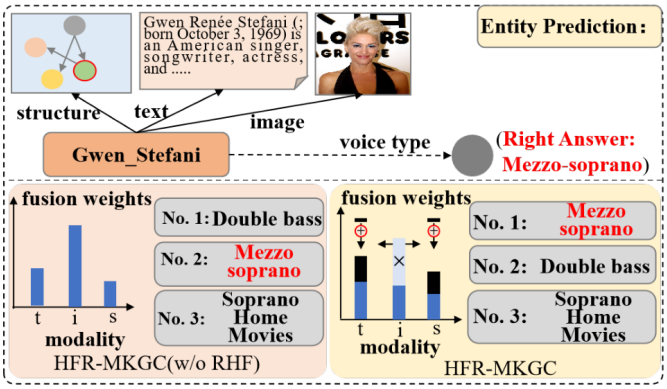
Phần lớn chỗ nhóm chưa thấy thuyết phục nằm ở phương pháp. Việc so vector CLIP với vector BERT bằng tích vô hướng ở (1) và (2) chỉ có nghĩa khi hai lớp chiếu đã đưa

Bảng III
KẾT QUẢ CHÍNH (%), RÚT GỌN TỪ BẢNG 1 CỦA [3]. TỐT NHẤT IN ĐẬM, TỐT THỨ HAI GẠCH CHÂN (TÍNH TRÊN TOÀN BỘ 14 MÔ HÌNH CƠ SỞ CỦA BÀI, KHÔNG CHỈ CÁC DÒNG HIỂN THỊ). LLAVA KHÔNG TÍNH ĐƯỢC MRR VÌ CHỈ SINH 10 ỨNG VIÊN.

| Mô hình | MKG-W | | | | MKG-Y | | | | DB15K | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | MRR | H@10 | H@3 | H@1 | MRR | H@10 | H@3 | H@1 | MRR | H@10 | H@3 | H@1 |
| RotatE [11] | 32,92 | 44,23 | 35,91 | 26,68 | 36,67 | 41,11 | 35,91 | 33,92 | 32,07 | 51,40 | 38,57 | 21,23 |
| RSME [5] | 33,41 | 44,31 | 35,80 | 27,59 | 38,03 | 44,02 | 35,80 | 34,28 | 33,72 | 50,39 | 39,23 | **24,45** |
| MyGO [15] | 33,40 | 44,36 | 35,38 | 27,52 | 30,29 | 42,17 | 35,38 | 23,75 | 32,25 | 48,23 | 35,49 | 24,19 |
| AdaMF-MAT [14] | 32,09 | 45,78 | 35,54 | 24,48 | 37,78 | 46,11 | 35,54 | 32,65 | 32,08 | 52,42 | 40,41 | 19,81 |
| APKGC [16] | 32,67 | 46,20 | 35,83 | 25,24 | 31,48 | 40,68 | 35,83 | 26,17 | 32,91 | 48,91 | 37,15 | 24,39 |
| NativE [6] | 36,79 | 50,28 | 40,47 | 29,36 | 38,34 | 46,24 | 40,47 | 33,49 | 33,59 | 53,77 | 40,67 | 22,11 |
| LLaVA [9] (chỉ suy diễn) | — | 26,42 | 22,29 | 15,02 | — | 03,58 | 02,80 | 01,64 | — | 15,89 | 13,15 | 08,32 |
| HFR-MKGC [3] | **38,62** | **51,66** | **42,12** | **31,37** | **39,00** | **47,31** | **42,12** | **34,41** | **35,20** | **56,41** | **43,25** | 23,04 |

Bảng IV
LOẠI BỎ TỪNG PHẦN TRÊN MKG-W (%), THEO BẢNG 3 CỦA [3]. CỘT CUỐI DO NHÓM TÍNH.

| Thiết lập | MRR | H@10 | H@3 | H@1 | ΔMRR |
|---|---|---|---|---|---|
| bỏ cấu trúc (S) | 25,67 | 39,42 | 28,81 | 18,02 | −12,95 |
| bỏ văn bản (T) | 29,67 | 45,61 | 34,92 | 21,25 | −8,95 |
| bỏ ảnh (V) | 31,16 | 47,39 | 36,10 | 22,09 | −7,46 |
| bỏ caption ảnh (VT) | 31,78 | 47,33 | 36,41 | 23,22 | −6,84 |
| bỏ RHF (trộn trung bình) | 31,98 | 50,25 | 39,14 | 20,80 | −6,64 |
| bỏ MER (không gợi ý LLaVA) | 33,52 | 50,61 | 39,70 | 23,42 | −5,10 |
| bỏ PTI (nhiễu ngẫu nhiên) | 34,59 | 50,95 | 40,03 | 25,12 | −4,03 |
| bỏ MNO (không đối kháng) | 34,01 | 50,98 | 40,26 | 24,13 | −4,61 |
| HFR-MKGC đầy đủ | **38,62** | **51,66** | **42,12** | **31,37** | — |




Hình 6. Nghiên cứu tình huống của tác giả (Hình 4 trong [3]): trọng số mô thức và thứ hạng ứng viên cho (Gwen Stefani, voice type, ?) khi không có và có RHF.

chúng về cùng một không gian. Thế nhưng bài không có hàm mất mát căn chỉnh riêng, cũng không nói có chuẩn hoá vector hay không, nên mọi sự căn chỉnh đều phải đi đường vòng qua hàm mất mát KGC. Cổng **g** thì không nhìn ngữ cảnh câu hỏi (Mục II-E), còn mẫu giả của MNO không được kiểm chứng là sai thật (Mục II-G). Thêm nữa, nhiều chi tiết cần để làm lại không được nêu: nội dung prompt, số epoch tinh chỉnh LoRA, cách chọn láng giềng đưa vào prompt, các hằng $\gamma$, $c$, $\mu_1$, nhiệt độ của hàm mất mát tự đối kháng, và tỉ lệ số bước cập nhật giữa $D$ và $G$.

Phần thực nghiệm cũng có vài chỗ cần nói. Mức cải thiện không đều: MKG-Y chỉ tăng 0,66 MRR, Hits@1 trên DB15K còn thua, nên câu "tốt nhất trên mọi độ đo" là nói quá. Nghiên cứu loại bỏ chỉ làm trên một bộ dữ liệu. Chi phí cũng bị bỏ qua: LLaVA-7B phải chạy cho mỗi ảnh (sinh caption), mỗi truy vấn (đưa gợi ý) và mỗi đoạn văn bản (viết lại), vậy mà bài không cho biết thời gian huấn luyện hay suy diễn so với mô hình cơ sở. Mã nguồn không công khai, nhiều mô hình cơ sở lại do tác giả tự chạy, nên người ngoài rất khó kiểm chứng.

Bài cũng bỏ ngỏ chuyện rò rỉ tri thức. LLaVA và BERT được tiền huấn luyện trên dữ liệu web, nên rất có thể đã "biết" sẵn nhiều sự thật trong Wikidata hay DBpedia. Nếu vậy, một phần đóng góp của MER đến từ trí nhớ của mô hình chứ không hẳn từ suy luận, và cách đọc kết quả ở Bảng IV sẽ khác đi.

Dù vậy, hai ý cốt lõi của bài theo nhóm là đúng hướng và đủ đơn giản để dùng lại: trọng số trộn mô thức nên phụ thuộc vào câu đang hỏi, và LLM nên đóng vai người gợi ý chứ không phải người chấm điểm. Cả hai ý đều không gắn với RotatE, có thể ghép vào hàm điểm khác.

## III. PHẦN B: MDBGF

### A. *Động lực và ý tưởng chính*

HFR-MKGC ở Phần A lo chuyện nên tin mô thức nào cho từng câu hỏi. MDBGF [4] bắt đầu từ một chỗ khác. Hầu hết mô hình MMKGC được huấn luyện trong điều kiện lý tưởng, thực thể nào cũng có đủ cấu trúc, ảnh và văn bản, và tác giả cho rằng chính điều kiện đó làm mô hình học lệch.

Bài nêu hai hiện tượng. Hiện tượng đầu là lệ thuộc mô thức: được xem đủ mọi thứ, mô hình sẽ bám vào mô thức dễ khai thác nhất, thường là mô thức nhiều thông tin, và lơ là phần còn lại. Hiện tượng sau là cạnh tranh mô thức [17]: các mô thức nhiễu ở mức khác nhau nhưng phải chia nhau một biểu diễn chung, nên ghép tất cả lại đôi khi còn tệ hơn dùng ít mô thức. Bảng 7 của bài có một con số minh hoạ khá rõ cho hiện tượng sau. Trên MKG-W, mô hình nền chỉ dùng cấu trúc và văn bản đạt MRR 38,9, thêm ảnh vào thì lại tụt còn 37,3.

Tác giả lấy ví dụ truy vấn (Taylor Swift, educated at, ?). Ảnh của cô chủ yếu là thảm đỏ Hollywood và nhà ở California, mô tả thì nói về sự nghiệp âm nhạc và chuyện sống ở Beverly Hills. Cả hai đều gợi tới California, nên mô hình nền đoán USC. Đáp án đúng lại nằm ở một đường đi thưa trong đồ thị:

Taylor Swift có bằng tiến sĩ danh dự do New York University trao. Một mô hình đã quen nghe theo ảnh và văn bản sẽ không để ý tới đường đi này.

Cách chữa của MDBGF, đúng như tên bài "Not all modalities at once", là không cho mô hình lúc nào cũng thấy đủ mọi mô thức. Bài gồm ba thành phần:

1) **MD** (Modality Dropout, rụng mô thức): trong lúc huấn luyện, thỉnh thoảng bỏ hẳn ảnh hoặc văn bản, luôn giữ cấu trúc, để mô hình phải học cách suy luận khi thiếu một mô thức.
2) **BGF** (Bidirectional Gated Fusion, hợp nhất có cổng hai chiều): khi không rụng, cho ảnh và văn bản cùng tham gia tính hệ số điều chỉnh của nhau trước khi trộn.
3) **AHNS** (Adaptive Hybrid Negative Sampling, lấy mẫu âm lai thích nghi): một hàm mất mát phụ trên tập mẫu âm gồm cả ứng viên ngẫu nhiên lẫn ứng viên điểm cao, với tỉ lệ ứng viên khó tăng dần theo epoch.

Có một điều bài viết không nói rõ nhưng đọc mã nguồn là thấy ngay: MDBGF dựng trên khung MyGO [15]. Lớp mô hình trong mã vẫn mang tên `MyGO` và giữ nguyên phần token hoá ảnh, văn bản, bộ mã hoá Transformer lẫn bộ giải mã có TuckER. Vì vậy nên xem MDBGF là MyGO cộng thêm ba mô-đun (AHNS thay chỗ hàm mất mát tương phản FGCL của MyGO) hơn là một kiến trúc mới. Hình 7 vẽ lại toàn bộ luồng xử lý.

### *B. Mã hoá thực thể*

MDBGF không dùng một vector duy nhất cho ảnh hay văn bản như HFR-MKGC, mà dùng cả một chuỗi token (đơn vị rời rạc, tương tự một từ trong câu):

- **Ảnh:** giữ tối đa 3 ảnh mỗi thực thể, đưa qua bộ token hoá của BEiT v2 [18]. Mỗi mảnh ảnh được gán vào một trong 8192 "từ thị giác" của bảng mã. Gom token từ các ảnh, rồi giữ tối đa 16 token theo một tiêu chí tần suất lấy từ MyGO: token nào xuất hiện nhiều ở thực thể này nhưng ít ở thực thể khác thì được ưu tiên giữ.
- **Văn bản:** làm tương tự với bộ token hoá của BERT [7], giữ tối đa 24 token.
- **Cấu trúc:** một hàng $\mathbf{e}_{\text{str}}$ trong bảng tham số, khởi tạo ngẫu nhiên và học từ đầu, giống HFR-MKGC.

Vector của từng token lấy từ bảng nhúng đã huấn luyện sẵn và giữ đóng băng, sau đó qua một lớp chiếu học được để về chiều $d = 256$. Như vậy $\mathbf{e}_{\text{vis}}$ là ma trận cỡ tối đa $16 \times d$ và $\mathbf{e}_{\text{txt}}$ là ma trận cỡ tối đa $24 \times d$, không phải một vector. Ở khâu đầu vào, đây là khác biệt lớn nhất so với Phần A. HFR-MKGC nhận một vector đã nén sẵn cho cả tấm ảnh, còn ở đây mô hình được nhìn từng mẩu nhỏ và có thể tự chọn mẩu nào đáng để ý.

### *C. MD: rụng mô thức theo lịch tăng dần*

Xác suất rụng tại epoch thứ $k$ trong tổng số $N$ epoch được định nghĩa là

$$P_{\text{drop}}(k) = \min\Big(\alpha,\ \frac{k}{N}\,\alpha\Big), \tag{11}$$

với $\alpha$ là mức trần, chọn bằng 0,3. Khi đến lượt rụng, tung thêm một đồng xu cân bằng để chọn bỏ ảnh hay bỏ văn bản. Mô thức bị bỏ được thay bằng vector 0 chứ không bị xoá khỏi chuỗi, nên chuỗi đưa vào bộ mã hoá có cùng độ dài trong mọi trường hợp.

*a) Tính thử vài giá trị.:* Do $k$ không bao giờ vượt $N$, $\frac{k}{N}\alpha$ cũng không bao giờ vượt $\alpha$, nên phép min thật ra không làm gì cả: lịch chỉ là một đường thẳng đi từ 0 lên $\alpha$ ở epoch cuối. Với $N = 5000$, xác suất rụng ở epoch 1000 là 0,06, ở epoch 2500 là 0,15 và chỉ chạm 0,3 ở epoch 5000. Tính trung bình cả quá trình thì chỉ khoảng 15% số lượt có rụng, mỗi mô thức phụ bị bỏ chừng 7,5%. Như vậy phần lớn thời gian mô hình vẫn thấy đủ ba mô thức (Hình 8).

*b) So với dropout thông thường.:* Dropout thông thường tắt ngẫu nhiên từng phần tử lẻ trong vector để chống quá khớp. MD thô hơn nhiều: mỗi lần rụng là mất trắng cả một mô thức của toàn bộ thực thể, còn cấu trúc thì không bao giờ bị đụng tới. Mục đích cũng khác. MD cố tình tạo ra những lúc mô hình chỉ có cấu trúc với ảnh, hoặc cấu trúc với văn bản, để nó không dồn hết niềm tin vào một mô thức phụ. Lịch tăng dần đi theo trực giác "học đủ trước, tập thiếu sau": đầu khoá cần đủ thông tin để các lớp chiếu học được gì đó, càng về sau mới nên tập cho mô hình quen với việc thiếu. Cơ chế này không tốn thêm tham số nào.

MD cũng không phải loại dropout duy nhất trong mô hình. Cấu hình kế thừa từ MyGO còn tắt ngẫu nhiên 90% phần tử của vector cấu trúc, 40% của token ảnh và 10% của token văn bản ở mỗi bước, nên câu "luôn giữ cấu trúc" chỉ đúng khi nói ở mức cả mô thức.

### *D. BGF: hai cổng cho ảnh và văn bản*

BGF chỉ chạy ở những lượt không rụng (trường hợp 1). Đầu tiên, mỗi mô thức được tóm lại thành một vector bằng cách lấy trung bình các token: $\bar{\mathbf{e}}_{\text{vis}}$ là trung bình các hàng của $\mathbf{e}_{\text{vis}}$, $\bar{\mathbf{e}}_{\text{txt}}$ là trung bình các hàng của $\mathbf{e}_{\text{txt}}$. Bài viết ghi là trung bình "theo chiều đặc trưng", nhưng công thức và mã nguồn đều cho thấy là trung bình theo chiều token. Hai vector tóm tắt được ghép lại rồi đưa vào hai cổng:

$$G_{v\to t} = \text{sigmoid}\big(W_{v\to t}\,[\bar{\mathbf{e}}_{\text{vis}};\,\bar{\mathbf{e}}_{\text{txt}}] + \mathbf{b}_{v\to t}\big) \in (0,1)^d, \tag{12}$$

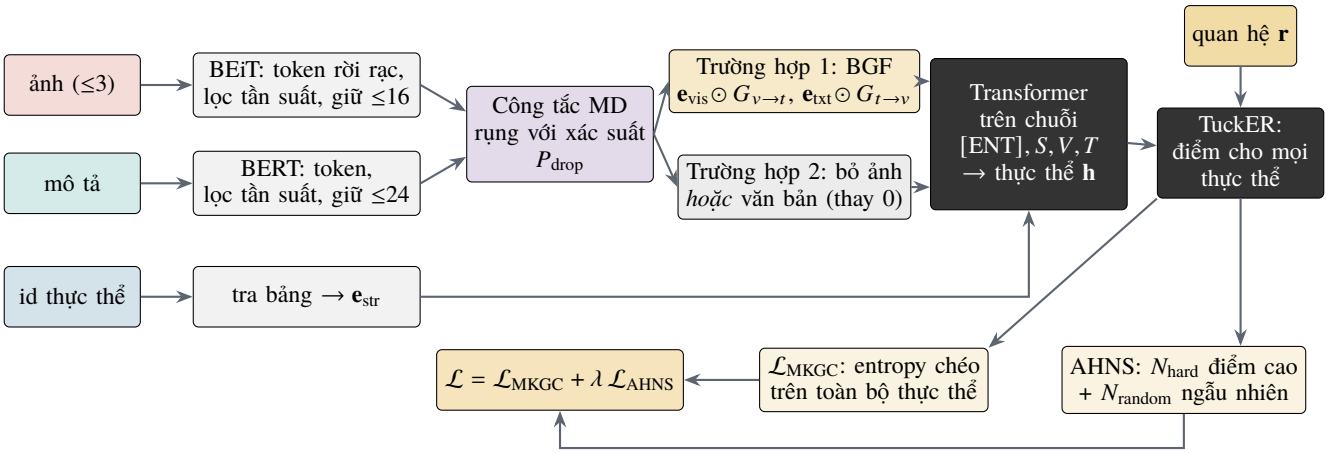
$$G_{t\to v} = \text{sigmoid}\big(W_{t\to v}\,[\bar{\mathbf{e}}_{\text{txt}};\,\bar{\mathbf{e}}_{\text{vis}}] + \mathbf{b}_{t\to v}\big) \in (0,1)^d, \tag{13}$$

với $W_{v\to t}, W_{t\to v} \in \mathbb{R}^{d\times 2d}$. Mỗi cổng là một vector $d$ chiều, nhân vào mọi token của mô thức tương ứng:

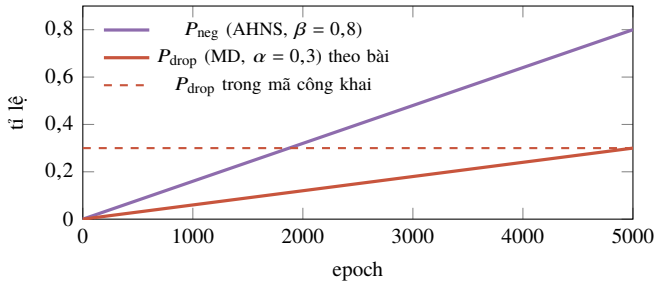
$$\mathbf{e}'_{\text{vis}} = \mathbf{e}_{\text{vis}} \odot G_{v\to t}, \qquad \mathbf{e}'_{\text{txt}} = \mathbf{e}_{\text{txt}} \odot G_{t\to v}. \tag{14}$$

Có thể hình dung mỗi cổng như một dãy núm vặn âm lượng, mỗi núm ứng với một chiều của mô thức, và vị trí các núm được chỉnh sau khi đã nhìn cả ảnh lẫn văn bản. Nếu văn bản đã mang thông tin ở một chiều nào đó, cổng có thể học cách vặn nhỏ chiều đó bên ảnh, và ngược lại. Chữ "hai chiều" trong tên gọi mang nghĩa này: ảnh góp phần quyết định hệ số của văn bản, văn bản góp phần quyết định hệ số của ảnh. BGF không chuyển nội dung từ mô thức này sang mô thức kia mà chỉ co giãn; việc trộn thật sự để cho Transformer ở bước sau. Hai cổng cộng lại có $2(2d^2 + d)$ tham số, khoảng 0,26 triệu với $d = 256$.

Đọc kỹ công thức thì thấy hai cổng nhận cùng một cặp vector, chỉ đổi thứ tự ghép, nên thực chất là hai cổng độc lập




Hình 7. Luồng dữ liệu của MDBGF, nhóm vẽ lại từ mô tả trong [4]. Cấu trúc không bao giờ đi qua công tắc MD. Công tắc chỉ hoạt động khi huấn luyện; khi suy diễn mô hình luôn đi nhánh trường hợp 1. Phần mã hoá ảnh, văn bản và bộ chấm điểm kế thừa từ MyGO [15].




Hình 8. Hai lịch tuyến tính của MDBGF với $N = 5000$ epoch, nhóm vẽ từ (11) và (18). Đường đứt nét là xác suất rụng thực tế trong mã nguồn tác giả công khai (Mục III-H). Hình do nhóm vẽ.

trên cùng một đầu vào. Đáng bàn hơn là cổng không hề nhận quan hệ $r$. Với Taylor Swift, hệ số co giãn sẽ y hệt nhau dù câu hỏi là educated at hay place of birth. Đặt cạnh Phần A thì đây chính là điểm yếu HFR-MKGC chỉ ra ở các phương pháp trước (Mục II-A), và BGF vẫn mắc phải.

Ở lượt có rụng (trường hợp 2), BGF bị bỏ qua và mô thức còn lại đi thẳng vào bước sau. Lúc suy diễn không có rụng nên mô hình luôn đi qua BGF.

### *E. Mã hoá chuỗi và hàm điểm TuckER*

Sau MD và BGF, mỗi thực thể thành một chuỗi

$$\mathbf{x} = \big[\,[\text{ENT}],\ \mathbf{e}_{\text{str}},\ \mathbf{e}_{\text{vis}}^{(\prime)},\ \mathbf{e}_{\text{txt}}^{(\prime)}\,\big], \tag{15}$$

trong đó [ENT] là một token học được đặt đầu chuỗi, dấu phẩy trên chỉ có ở trường hợp 1, còn ở trường hợp 2 một trong hai khối cuối là 0. Chuỗi qua một bộ mã hoá Transformer [19]; vector ở vị trí [ENT] là biểu diễn cuối $\mathbf{h}$ của thực thể. Cũng như Phần A, biểu diễn này không phụ thuộc quan hệ.

Điểm của bộ ba được tính bằng TuckER [20]:

$$S(h, r, t) = \mathcal{W} \times_1 \mathbf{h} \times_2 \mathbf{r} \times_3 \mathbf{t}, \tag{16}$$

với $\mathcal{W}$ là một tensor lõi ba chiều học được. Công thức (16) dễ hình dung hơn nếu tách làm hai bước: nhân $\mathcal{W}$ với $\mathbf{r}$ theo chiều thứ hai cho ra một ma trận $M_r$ riêng cho quan hệ $r$, và điểm chính là dạng song tuyến $\mathbf{h}^\top M_r\,\mathbf{t}$. So với RotatE ở Phần A (quan hệ là phép xoay, giữ nguyên độ dài), $M_r$ là một ma trận tuỳ ý, nên biểu diễn được nhiều kiểu quan hệ hơn nhưng không còn tính chất hình học rõ ràng như "đối xứng là xoay 180°". Tensor lõi được chia sẻ giữa mọi quan hệ, nên số tham số không tăng theo $|\mathcal{R}|$ nhiều như khi mỗi quan hệ có một ma trận riêng.

Mô hình được huấn luyện bằng hàm mất mát entropy chéo (cross-entropy) trên toàn bộ tập thực thể: với mỗi $(h, r, t)$, mọi $t' \in \mathcal{E}$ đều là ứng viên và $t$ là nhãn đúng.

$$\mathcal{L}_{\text{MKGC}} = -\sum_{(h,r,t)} \log \frac{\exp S(h, r, t)}{\sum_{t' \in \mathcal{E}} \exp S(h, r, t')}. \tag{17}$$

Đây là cách huấn luyện "1-N" quen thuộc của TuckER, khác HFR-MKGC dùng mẫu âm và hàm mất mát tự đối kháng của RotatE. Hai chiều $(h, r, ?)$ và $(?, r, t)$ đều được huấn luyện theo cùng cách.

### *F. AHNS: mẫu âm ngẫu nhiên chuyển dần sang mẫu âm khó*

Hàm (17) vốn đã so đáp án đúng với mọi thực thể, vậy AHNS thêm được gì? Trong một mẫu số có tới 15000 số hạng, vài ứng viên khó (điểm cao nhưng sai) chỉ chiếm một phần nhỏ của gradient. AHNS lập thêm một bài phân loại nhỏ gồm đáp án đúng và $N_{\text{neg}} = 20$ ứng viên sai, trong đó có một phần là ứng viên khó, để mô hình phải tập trung đẩy đúng những ứng viên này xuống.

Tỉ lệ ứng viên khó tăng theo cùng kiểu lịch với MD:

$$P_{\text{neg}}(k) = \min\Big(\beta,\ \frac{k}{N}\,\beta\Big), \qquad N_{\text{hard}} = N_{\text{neg}}\,P_{\text{neg}}, \qquad N_{\text{random}} = N_{\text{neg}} - N_{\text{hard}}. \tag{18}$$

Ứng viên khó là $N_{\text{hard}}$ thực thể sai có điểm cao nhất theo chính mô hình hiện tại; phần còn lại lấy ngẫu nhiên. Với $\beta = 0{,}8$: ở epoch 2500 có 8 ứng viên khó và 12 ngẫu nhiên; đến epoch cuối là 16 và 4. Lịch này hợp lý ở chỗ: đầu khoá mô hình còn yếu nên những ứng viên điểm cao phần lớn chỉ là nhiễu, lấy ngẫu nhiên cho đa dạng thì tốt hơn; về sau, ứng viên điểm cao mới thật sự là thứ dễ gây nhầm.

Hàm mất mát cuối cùng là

$$\mathcal{L} = \mathcal{L}_{\text{MKGC}} + \lambda\, \mathcal{L}_{\text{AHNS}}, \tag{19}$$

trong đó $\mathcal{L}_{\text{AHNS}}$ là entropy chéo trên tập 21 ứng viên vừa lập, và $\lambda = 0{,}01$ trên MKG-W. Chi phí thêm gần như bằng 0 vì điểm của mọi thực thể đã được tính sẵn cho (17); AHNS chỉ chọn lại từ bảng điểm đó.

Mẫu âm trong AHNS luôn là các thực thể khác, không phải phiên bản bóp méo của chính thực thể như MNO của HFR-MKGC hay AdaMF [14].

### G. Thực nghiệm

*a) Thiết lập.:* Ba bộ dữ liệu như Bảng I. Huấn luyện 5000 epoch, batch 2048 (MKG-Y dùng 1024 theo kịch bản chạy của tác giả), $d = 256$, trên một GPU A800. Các mô hình cơ sở phần lớn lấy số từ bài gốc của chúng; riêng một số ô của MoMoK do tác giả MDBGF tự chạy lại. Lưu ý: bảng thống kê của MDBGF ghi mọi thực thể DB15K đều có văn bản, khác con số 70,7% ở Bảng I. Bài không giải thích chênh lệch này, nhiều khả năng do hai bài dùng nguồn mô tả khác nhau.

*b) Kết quả chính.:* Bảng V rút gọn từ Bảng 1 của bài, giữ RotatE và TuckER làm mốc, cùng MyGO (khung nền) và các mô hình MMKGC mạnh nhất. Có bốn điểm đáng nói:

1) Trên MKG-W, MRR tăng 2,70 điểm so với APKGC, một khoảng cách đáng kể. Hai bộ còn lại thì khiêm tốn hơn nhiều: 0,79 điểm trên DB15K và 0,21 điểm trên MKG-Y so với MCKGC. Bài trình bày mức tăng bằng phần trăm tương đối (7,22%, 1,99%, 0,54%) nên đọc qua dễ tưởng cách biệt lớn hơn thực tế.
2) MDBGF dẫn đầu 11/12 ô. Ô còn lại là Hits@1 trên MKG-Y (35,15 so với 35,49 của MCKGC), được bài ghi bằng dấu "–" ở dòng "Improvements". Khá trùng hợp là HFR-MKGC cũng dẫn đầu 11/12 ô và cũng thua ở một ô Hits@1.
3) Dòng "Improvements" tính sai một ô. Hits@1 trên DB15K được ghi tăng 2,66%, tức là đem so với MCKGC (31,92), trong khi MoMoK cùng bảng đạt 32,38. So với MoMoK thì mức tăng chỉ khoảng 1,20%.
4) Con số đáng nhìn nhất có lẽ là mức tăng so với MyGO, vì hai mô hình dùng chung phần mã hoá và chấm điểm: MRR tăng 4,00 điểm trên MKG-W, 2,56 trên MKG-Y và 2,86 trên DB15K. Đó là phần đóng góp của ba mô-đun mới.

*c) Loại bỏ từng phần.:* Bảng VI gộp ba bảng phân tích của bài, đều trên MKG-W. Bỏ mô-đun nào cũng mất khoảng 1,4–1,5 điểm MRR. Ba mức gần như bằng nhau, lại không có độ lệch giữa các lần chạy, nên không thể nói mô-đun nào quan trọng hơn. Khi thay BGF, tác giả dùng một cơ chế trộn bằng chú ý đơn giản chứ không bỏ hẳn bước trộn.

Về cách rụng, chỉ bỏ ảnh hoặc chỉ bỏ văn bản đều thua cách bỏ ngẫu nhiên một trong hai khoảng 1,3 điểm MRR. Bỏ cả hai cùng lúc (nhóm hiểu là chỉ còn cấu trúc) nằm ở giữa. Điều này khớp với lập luận rằng mô hình cần gặp nhiều kiểu thiếu khác nhau.

Phần thời điểm rụng thì cho kết quả khó hiểu. Tác giả lấy mốc epoch 500 rồi thử chỉ rụng trước mốc hoặc chỉ rụng sau mốc. Cả hai cách đều thua hẳn việc không rụng gì (34,61 và 37,06 so với 38,63). Nói cách khác, MD chỉ có lợi với đúng lịch tuyến tính, còn đặt sai thời điểm thì mất tới 4 điểm. Bài không giải thích chuyện này, và nhóm thấy đây là chỗ cần làm rõ trước khi gọi MD là "bền vững".

*d) Cạnh tranh mô thức và thử nghiệm thiếu dữ liệu.:* Với mô hình nền (bỏ cả MD và BGF), bài thử các tổ hợp mô thức khi suy diễn. Đủ ba mô thức đạt MRR 37,3; cấu trúc + văn bản đạt 38,9; cấu trúc + ảnh đạt 36,7; ảnh + văn bản (bỏ cấu trúc) đạt 36,4. Ảnh trên MKG-W rõ ràng đang làm hại mô hình nền, đúng như động lực của bài. Nhưng bảng này còn cho thấy một điều bài không nhắc tới: chỉ cần bỏ ảnh khỏi mô hình nền là được 38,9, cao hơn cả bản bỏ MD (38,63) lẫn bản bỏ BGF (38,70) của MDBGF. So với cách làm đơn giản "bỏ ảnh đi", MD và BGF cộng lại chỉ hơn khoảng 1,2 điểm MRR (40,10 so với 38,9).

Để thử độ bền, tác giả che bớt mô thức trên tập kiểm thử theo đúng cách MD làm khi huấn luyện, và MRR giảm từ 40,10 xuống 38,19. Trong cả bài, chỉ thực nghiệm này đo trực tiếp chữ "robust" ở tiêu đề. Tiếc là không có mô hình cơ sở nào được chạy trong cùng điều kiện, nên chưa thể nói MDBGF bền hơn các phương pháp khác.

*e) Tính tổng quát và chi phí.:* Theo Hình 3 của bài, cắm MD vào MyGO và AdaMF đều làm tăng kết quả trên MKG-W. Bài chỉ vẽ biểu đồ cột, không ghi số, nên ở đây không trích lại. Về chọn cặp mô thức cho BGF (Hình 4 của bài), cặp ảnh–văn bản cho mức tăng lớn nhất; các cặp có cấu trúc tham gia cổng cho mức tăng thấp hơn. Bảng VII so AHNS với hai cách lấy mẫu âm của MyGO (FGCL, tương phản mịn) và AdaMF (sinh nhiễu đối kháng). Về độ chính xác, AHNS chỉ hơn FGCL 0,12 điểm MRR, nhỏ tới mức khó coi là khác biệt thật. Cái AHNS thắng rõ là bộ nhớ: khoảng 21 GB so với 40 GB và 53 GB. Gắn AHNS vào chính MyGO thay cho FGCL cũng tăng MRR từ 36,10 lên 37,50. Toàn bộ ba mô-đun chỉ làm tăng bộ nhớ khoảng 3% so với mô hình nền (21286 MB so với 20622 MB), phần lớn do hai cổng của BGF.

*f) Siêu tham số.:* Tác giả quét ba giá trị cho mỗi siêu tham số chính trên MKG-W: $\alpha \in \{0{,}15;\ 0{,}3;\ 0{,}45\}$, $\beta \in \{0{,}4;\ 0{,}6;\ 0{,}8\}$, $\lambda \in \{0{,}1;\ 0{,}01;\ 0{,}001\}$ và $N_{\text{neg}}$ từ 5 tới 40. Xét theo MRR, giá trị được chọn luôn là tốt nhất, và mọi biến thể chỉ kém dưới 1 điểm. Như vậy phương pháp không quá nhạy với siêu tham số. Nhưng cũng vì chênh lệch nhỏ như thế, với một lần chạy duy nhất khó biết giá trị "tốt nhất" tốt thật hay chỉ do may. Bài cũng cho thấy MD có ích nhiều hơn khi giữ nhiều token ảnh và văn bản hơn, tức khi mô thức phụ chứa nhiều thông tin nhưng cũng nhiều nhiễu.

*g) Tái lập của nhóm.:* [Chạy lại MDBGF trên MKG-W bằng mã nguồn tác giả. Ghi WandB công khai và gắn link ngay cạnh: (1) kết quả chính, (2) loại bỏ từng phần, (3) so sánh lịch rụng theo bài và theo mã. Link repo GitHub của nhóm đặt tại đây.]

### H. Đối chiếu bài báo với mã nguồn công khai

Vì mã nguồn có công khai [4], nhóm đọc thêm mã để gỡ những chỗ bài viết còn mơ hồ. Bảng VIII ghi lại các điểm mà mã (bản trên GitHub, commit `c512d79`) khác với bài. Cần nói rõ là nhóm không biết các con số trong bài có được chạy từ

Bảng V

KẾT QUẢ CHÍNH CỦA MDBGF (%), RÚT GỌN TỪ BẢNG 1 CỦA [4]. TỐT NHẤT IN ĐẬM, TỐT THỨ HAI GẠCH CHÂN (TÍNH TRÊN TOÀN BỘ 17 MÔ HÌNH CƠ SỞ CỦA BÀI, KHÔNG CHỈ CÁC DÒNG HIỂN THỊ). SỐ CỦA MÔ HÌNH CƠ SỞ LẤY TỪ BÀI GỐC CỦA CHÚNG NÊN CÓ THỂ KHÁC BẢNG III. APKGC KHÔNG BÁO CÁO TRÊN MKG-Y.

| Mô hình | MKG-W | | | | MKG-Y | | | | DB15K | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | MRR | H@10 | H@3 | H@1 | MRR | H@10 | H@3 | H@1 | MRR | H@10 | H@3 | H@1 |
| RotatE [11] | 33,67 | 46,73 | 36,68 | 26,80 | 34,95 | 45,30 | 38,35 | 29,10 | 29,28 | 49,66 | 36,12 | 17,87 |
| TuckER [20] | 30,39 | 41,25 | 32,91 | 24,44 | 37,05 | 41,45 | 38,43 | 34,59 | 33,86 | 50,38 | 37,91 | 25,33 |
| AdaMF [14] | 34,27 | 47,21 | 37,86 | 27,21 | 38,06 | 45,48 | 40,44 | 33,49 | 32,51 | 51,68 | 39,67 | 21,31 |
| MyGO [15] | 36,10 | 47,75 | 38,54 | 29,78 | 36,57 | 41,76 | 38,40 | 33,48 | 37,72 | 52,21 | 41,26 | 30,08 |
| MoMoK [21] | 35,89 | 45,48 | 37,08 | 30,38 | 37,91 | 42,38 | 39,15 | 35,09 | 39,57 | 54,14 | 43,45 | 32,38 |
| SRE [22] | 37,20 | 48,90 | 39,90 | 30,80 | 37,30 | 42,90 | 39,20 | 34,50 | 37,60 | 51,50 | 41,00 | 30,30 |
| APKGC [16] | 37,40 | 50,10 | 40,40 | 30,60 | — | — | — | — | 36,40 | 52,70 | 41,30 | 28,20 |
| MCKGC [23] | 36,88 | 47,43 | 38,92 | 31,32 | 38,92 | 45,21 | 40,57 | **35,49** | 39,79 | 54,66 | 43,80 | 31,92 |
| MDBGF [4] | **40,10** | **52,35** | **42,83** | **33,42** | **39,13** | **46,06** | **40,78** | 35,15 | **40,58** | **55,53** | **44,23** | **32,77** |

Bảng VI

PHÂN TÍCH MDBGF TRÊN MKG-W (%), NHÓM GỘP TỪ BẢNG 2, 3, 4 CỦA [4]. CỘT CUỐI DO NHÓM TÍNH.

| Thiết lập | MRR | H@10 | H@3 | H@1 | ΔMRR |
|---|---|---|---|---|---|
| bỏ MD (luôn đủ mô thức) | 38,63 | 50,63 | 40,93 | 32,34 | −1,47 |
| bỏ BGF (trộn bằng chú ý) | 38,70 | 51,20 | 40,91 | 32,35 | −1,40 |
| bỏ AHNS | 38,63 | 50,80 | 41,62 | 31,91 | −1,47 |
| chỉ rụng ảnh | 38,84 | 51,49 | 41,09 | 32,41 | −1,26 |
| chỉ rụng văn bản | 38,77 | 50,88 | 41,39 | 32,24 | −1,33 |
| rụng cả hai | 39,27 | 51,23 | 41,62 | 32,76 | −0,83 |
| chỉ rụng trước epoch 500 | 34,61 | 46,44 | 36,38 | 28,54 | −5,49 |
| chỉ rụng sau epoch 500 | 37,06 | 49,70 | 39,58 | 30,42 | −3,04 |
| MDBGF đầy đủ | **40,10** | **52,35** | **42,83** | **33,42** | — |

Bảng VII

SO SÁNH CÁCH LẤY MẪU ÂM TRÊN MKG-W, NHÓM GHÉP TỪ BẢNG 5 VÀ 6 CỦA [4]. BỘ NHỚ LÀ ĐỈNH BỘ NHỚ GPU KHI HUẤN LUYỆN.

| Mẫu âm bổ sung (trên MD + BGF) | MRR | H@1 | Bộ nhớ (MB) |
|---|---|---|---|
| không có | 38,63 | 31,91 | 21284 |
| FGCL của MyGO [15] | 39,98 | 33,36 | 39551 |
| Nhiễu đối kháng của AdaMF [14] | 39,32 | 33,06 | 53350 |
| AHNS | **40,10** | **33,42** | 21286 |

Bảng VIII

KHÁC BIỆT GIỮA BÀI BÁO VÀ MÃ NGUỒN CÔNG KHAI CỦA MDBGF (NHÓM ĐỐI CHIẾU TỪ TỆP `TRAIN_MYGO_FGC.PY` VÀ `MODEL_MYGO.PY`).

| Điểm | Bài báo | Mã công khai |
|---|---|---|
| Xác suất rụng | tăng tuyến tính tới $\alpha$ (11) | hằng số 0,3; $P_{\text{drop}}$ được truyền vào nhưng dòng dùng nó bị chú thích bỏ |
| Đơn vị rụng | mỗi epoch | mỗi batch; một lần tung xu áp cho mọi thực thể |
| Mã hoá thực thể | một Transformer trên chuỗi (15) | mã hoá riêng ba chuỗi [ENT]+$S$, [ENT]+$V$, [ENT]+$T$ rồi cộng bốn vector; bước softmax chạy trên một chiều độ dài 1 nên mọi trọng số bằng 1 |
| Hàm điểm | TuckER (16) | Transformer giải mã trên $(h, r, [\text{MASK}])$ rồi mới qua tầng TuckER (kế thừa MyGO) |
| Mẫu âm khó | lấy trong tập thực thể của batch | lấy top điểm trên toàn bộ thực thể |
| Chọn kết quả | không nêu | đánh giá mỗi 50 epoch; báo cáo lần có MRR *trên tập kiểm thử* cao nhất |

đúng phiên bản mã này hay không; bảng chỉ ghi những gì đọc được.

Đáng lo nhất là dòng cuối. Kết quả "tốt nhất" được giữ lại theo MRR trên tập kiểm thử chứ không theo tập kiểm định, tức là trong 100 lần đánh giá, lần nào đẹp nhất trên tập kiểm thử thì lấy lần đó. Cách chọn này luôn nghiêng về phía có lợi, trong khi các chênh lệch ở Bảng VI chỉ cỡ 1,5 điểm. Dòng đầu bảng cũng đặt ra một câu hỏi: nếu mã không dùng lịch tuyến tính, thì thí nghiệm rụng trước/sau epoch 500 và phần quét $\alpha$ được chạy bằng phiên bản nào?

### *I. Nhận xét và hạn chế*

Điểm nhóm thấy yếu nhất ở phần phương pháp là BGF. Cổng không nhận quan hệ, nên ảnh hay văn bản của một thực thể được tin ở mức như nhau cho mọi câu hỏi. Vậy mà ví dụ Taylor Swift trong bài lại kể rằng BGF "nhận ra ảnh không khớp với quan hệ học vấn" rồi nén ảnh xuống, điều mà (12)–(14) không cho phép. Các tỉ lệ "50% ảnh, 35% văn bản, 15% cấu trúc" trong bảng tình huống cũng không ứng với đại lượng nào trong mô hình. Cùng ví dụ đó còn nói MD có lúc buộc mô hình "chỉ dựa vào cấu trúc", trái với (11) vốn mỗi lần chỉ bỏ một mô thức phụ. Vì vậy nhóm chỉ xem ví dụ này là minh hoạ cho ý tưởng chứ không phải bằng chứng.

Một vấn đề khác là huấn luyện và suy diễn không khớp nhau. BGF chỉ được học ở những lượt không rụng nhưng lúc suy diễn thì luôn được dùng. Ngược lại, bộ mã hoá phải học cách xử lý những khối toàn số 0 mà khi suy diễn không bao giờ gặp, trừ thí nghiệm thiếu dữ liệu. Phép min thừa trong (11) và (18) (Mục III-C) thì chỉ là chuyện trình bày, không ảnh hưởng kết quả.

Về thực nghiệm, cách trình bày làm kết quả trông tốt hơn thực tế. Mức tăng được ghi bằng phần trăm tương đối, trong khi tính theo điểm thì MRR chỉ tăng 0,21 trên MKG-Y và 0,79 trên DB15K. Mô hình thua một ô và có một ô tính sai mức tăng, nên câu "vượt trội nhất quán" là nói quá. Mọi phân

tích phụ đều chỉ làm trên MKG-W, mỗi cấu hình chạy một lần với hạt giống cố định và không có độ lệch chuẩn, trong khi phần lớn chênh lệch chỉ 1–1,5 điểm. Kết quả rụng chỉ trước hoặc chỉ sau epoch 500 thua cả không rụng mà không được giải thích. Việc bỏ ảnh khỏi mô hình nền đã đạt 38,9 cũng làm phần đóng góp riêng của MD và BGF nhỏ hơn cách bài trình bày. Thí nghiệm thiếu dữ liệu thì không có mô hình đối chứng, và kiểu thiếu được tạo ra lại đúng là kiểu mô hình đã tập để chịu. Cuối cùng, số của các mô hình cơ sở lấy từ bài gốc với thiết lập khác nhau: cùng là APKGC trên MKG-W, Bảng III ở Phần A ghi MRR 32,67, còn Bảng V ghi 37,40.

Về khả năng tái lập, việc công khai mã là điểm cộng lớn so với HFR-MKGC. Có điều mã khác bài ở những chỗ cốt lõi (Bảng VIII), và cách chọn kết quả theo tập kiểm thử khiến các con số báo cáo dễ lạc quan hơn thực tế.

Bỏ qua những điểm trên, ý tưởng chính của MDBGF vẫn đơn giản, rẻ và có cơ sở. Cho mô hình xem đủ mọi mô thức không phải lúc nào cũng tốt, và cố tình giấu bớt một mô thức là một cách điều hoà không tốn tham số, có thể gắn vào nhiều mô hình khác. AHNS cũng cho thấy khi đã có sẵn bảng điểm 1-N thì lấy mẫu âm khó gần như không tốn gì. Cả ba mô-đun đều không phụ thuộc hàm điểm, nên về nguyên tắc có thể ghép chung với cơ chế trộn theo quan hệ của HFR-MKGC.

## IV. Đối chiếu hai bài và kết luận

[Viết hoàn chỉnh mục này; dưới đây là đoạn sơ bộ.] Điểm đối chiếu nhóm đã thấy từ phía HFR-MKGC: hai bài cùng dùng ba bộ dữ liệu, cùng đặt câu hỏi "dùng ảnh và văn bản thế nào cho bền vững", nhưng chọn hai giả định ngược nhau về các biến thể của một thực thể. HFR-MKGC coi bản bóp méo của một thực thể là mẫu âm cần đẩy xa; MDBGF coi bản thiếu ảnh hoặc thiếu văn bản vẫn là chính thực thể đó và vẫn phải dự đoán đúng. Trọng số mô thức của HFR-MKGC phụ thuộc quan hệ; cổng của MDBGF thì không. Cả hai đều không có hàm mất mát căn chỉnh mô thức riêng. HFR-MKGC đưa LLM vào vòng lặp với chi phí lớn và không công khai mã; MDBGF không dùng LLM, tăng bộ nhớ khoảng 3% và có mã công khai. Số liệu mô hình cơ sở ở hai bài lệch nhau đáng kể (Mục III-I), nên không thể so trực tiếp MRR 38,62 của HFR-MKGC với 40,10 của MDBGF trên MKG-W.

## Tài liệu tham khảo


[1] D. Xu, T. Xu, S. Wu, J. Zhou, and E. Chen, "Relation-enhanced negative sampling for multimodal knowledge graph completion," in *Proc. 30th ACM Int. Conf. Multimedia*, 2022, pp. 3857–3866.

[2] Y. Liu, H. Li, A. Garcia-Duran, M. Niepert, D. Onoro-Rubio, and D. S. Rosenblum, "MMKG: Multi-modal knowledge graphs," in *Proc. Eur. Semantic Web Conf. (ESWC)*, 2019, pp. 459–474.

[3] D. Wang, J. Du, Z. Xue, M. Liang, G. Ye, Y. Shao, and H. Li, "HFR-MKGC: Hierarchical fusion reasoning with MLLMs for multi-modal knowledge graph completion," in *Proc. AAAI Conf. Artif. Intell.*, vol. 40, no. 18, 2026, pp. 15 815–15 823.

[4] J. Peng, F. Zhang, H. Chen, J. Cheng, Y. Ning, and X. Wang, "Not all modalities at once: Dynamic dropout and bidirectional fusion for robust multi-modal knowledge graph completion," in *Findings of the Association for Computational Linguistics: ACL 2026*, 2026, pp. 17 928–17 940.

[5] M. Wang, S. Wang, H. Yang, Z. Zhang, X. Chen, and G. Qi, "Is visual context really helpful for knowledge graph? A representation learning perspective," in *Proc. 29th ACM Int. Conf. Multimedia*, 2021, pp. 2735–2743.

[6] Y. Zhang, Z. Chen, L. Guo, Y. Xu, B. Hu, Z. Liu, W. Zhang, and H. Chen, "NativE: Multi-modal knowledge graph completion in the wild," in *Proc. 47th Int. ACM SIGIR Conf. Res. Develop. Inf. Retrieval*, 2024, pp. 91–101.

[7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. NAACL-HLT*, 2019, pp. 4171–4186.

[8] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, "Learning transferable visual models from natural language supervision," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2021, pp. 8748–8763.

[9] H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 36, 2023, pp. 34 892–34 916.

[10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2022.

[11] Z. Sun, Z.-H. Deng, J.-Y. Nie, and J. Tang, "RotatE: Knowledge graph embedding by relational rotation in complex space," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2019.

[12] T. Trouillon, J. Welbl, S. Riedel, É. Gaussier, and G. Bouchard, "Complex embeddings for simple link prediction," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2016, pp. 2071–2080.

[13] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, and A. Courville, "Improved training of Wasserstein GANs," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.

[14] Y. Zhang, Z. Chen, L. Liang, H. Chen, and W. Zhang, "Unleashing the power of imbalanced modality information for multi-modal knowledge graph completion," in *Proc. Joint Int. Conf. Comput. Linguistics, Lang. Resour. Eval. (LREC-COLING)*, 2024, pp. 17 120–17 130.

[15] Y. Zhang, Z. Chen, L. Guo, Y. Xu, B. Hu, Z. Liu, W. Zhang, and H. Chen, "Tokenization, fusion, and augmentation: Towards fine-grained multi-modal entity representation," in *Proc. AAAI Conf. Artif. Intell.*, vol. 39, 2025, pp. 13 322–13 330.

[16] Y. Jian, X. Luo, Z. Li, M. Zhang, Y. Zhang, K. Xiao, and X. Hou, "APKGC: Noise-enhanced multi-modal knowledge graph completion with attention penalty," in *Proc. AAAI Conf. Artif. Intell.*, vol. 39, 2025, pp. 15 005–15 013.

[17] Y. Huang, J. Lin, C. Zhou, H. Yang, and L. Huang, "Modality competition: What makes joint training of multi-modal network fail in deep learning? (provably)," in *Proc. Int. Conf. Mach. Learn. (ICML)*, 2022, pp. 9226–9259.

[18] Z. Peng, L. Dong, H. Bao, Q. Ye, and F. Wei, "BEiT v2: Masked image modeling with vector-quantized visual tokenizers," *arXiv preprint arXiv:2208.06366*, 2022.

[19] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.

[20] I. Balažević, C. Allen, and T. Hospedales, "TuckER: Tensor factorization for knowledge graph completion," in *Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP-IJCNLP)*, 2019, pp. 5185–5194.

[21] Y. Zhang, Z. Chen, L. Guo, Y. Xu, B. Hu, Z. Liu, W. Zhang, and H. Chen, "Multiple heads are better than one: Mixture of modality knowledge experts for entity representation learning," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2025.

[22] Y. Wang, B. Ning, X. Wang, C. Liu, and G. Li, "Segmentation similarity enhanced semantic related entity fusion for multi-modal knowledge graph completion," in *Proc. 48th Int. ACM SIGIR Conf. Res. Develop. Inf. Retrieval*, 2025, pp. 1176–1185.

[23] Y. Gao, F. Zhang, Z. Zhang, X. Min, and F. Zhuang, "Mixed-curvature multi-modal knowledge graph completion," in *Proc. AAAI Conf. Artif. Intell.*, vol. 39, 2025, pp. 11 699–11 707.